卒業研究「同一ツール引数乗っ取りIPI下の内部表現と引数選好」の新規性評価と軌道修正案（調査日：2026-11-05）

結論：研究全体はまだスクープされていません。ただし、新規性が残っているのは「引数内容」の内部表現と、それが権限の帰属とどう結び付くかという部分だけです。「権限・役割の内部表現が攻撃成功を予測する」という柱は、Ye et al.（ICML 2026）とYu et al.（arXiv:2610.05295、2026-10）がすでに示しています。「同一ツールで引数だけを変える攻撃」という問題設定も、2026年5〜11月に防御・監査系の論文（PACT、Liao、Influence Is Not Authority、AuthorityFlow）が相次いで扱いました。さらに、現在の負の結果（生成直前の1トークン状態からは引数内容を線形に読み出せない）を踏まえると、計画どおりの「Tend_assistantでのargument_readout × authority」という確認的解析は成立しにくいと判断します。そこで、**「引数の値は生成直前に保持されているのではなく、引数スロットを生成する時点で文脈から取り出される。その取り出し元（user由来かtool由来か）を内部でどう決めているか」を問う研究に軌道修正すること**を推奨します。

TL;DR

- **新規性は残るが範囲は狭まった。** 同一ツール引数乗っ取りという攻撃面は2026年に防御・監査研究で既出です。役割・権限の内部表現が攻撃成功を予測することもYe et al.（ICML 2026）とYu et al.（2610.05295）で既出です。未着手と見られるのは、IPI下で「引数値そのもの」を内部から読み出し、それを権限帰属と交互作用させて行動選好を説明する部分です。
- **計画のままでは主要測定が破綻する可能性が高い。** 生成直前トークンでのprobeは最大AUROC 0.613で、モデル自身の対数確率（AUROC換算0.87〜0.91）と大きく乖離しています。これは、引数内容は線形に操舵できない（Wu et al. 2605.07990）、束縛情報は実体トークン上にありポインタ的に取り出される（ICLR 2026の束縛機構研究）、という先行知見と整合的です。
- **推奨は案A「引数スロット時点での取り出し元の因果追跡」。** 既存資産（672条件、全36層capture、教師強制スコアリング）の再利用度が高く、11月中に核心実験を終えられます。負の結果は「どこに無いか」を示す先行実験として、そのまま論文の第1節に使えます。投稿先はACL 2027（ARR 2027-01-04締切、公式）を最短とし、現実的にはICML 2027（1月下旬と予測、未公表）か各種ワークショップを狙います。

Key Findings

1. 要素別の新規性判定

研究要素	判定	根拠となる論文（公開日・版・査読状況）
同一ツールの引数乗っ取りに特化	**部分的に実施**（攻撃面の定義・防御・監査は既出。内部表現研究は未実施）	AuthorityFlow / FactAuthBench（arXiv:2611.04673 v1、2026-11-03、査読前）：「intended actionは保ったまま引数を操作する」parameter poisoningを定義。AgentDojoを拡張した144ペアで、防御なしASR 93.06%をAuthorityFlowが9.03%まで下げた。 arxiv arxiv PACT（Fan et al.、arXiv:2605.11039 v1、2026-05-11、査読前）：引数単位のprovenance契約。AgentDojoで最も強い3モデルに対しセキュリティ100%を達成しつつ、有用性を38.1〜46.4%回復し、CaMeLを8〜16ポイント上回った。Liao（arXiv:2607.20827 v1、2026-07-23、査読前）：ツール・引数ごとの権限監査を450タスクで実施。 arxiv arxiv Influence Is Not Authority（Ahad et al.、arXiv:2608.29942 v1、2026-08-30、査読前）：24の基本ケースから作った96条件を監査。送金先の値の出所を移すだけで、因果ガードレールの信号がLlama・Gemma両スコアラーのもとで24件すべてで攻撃側へずれる
argument_readout（引数内容の内部読み出し）	**未実施と見られる**	Wu et al.（arXiv:2605.07990 v1、2026-05-08、査読前）は、ツールの同一性は線形に読めて操舵もできるが、引数値は操舵できないと報告（同一ツールで「Tokyo」を「Paris」に向ける操舵は0/30）。 arxiv arxiv 注入下の設定は扱っていない。2608.27750（2026-08）は生成済みツール呼び出しの最終トークンで「誤った値」を検出するが、注入は扱わない。 arxiv サブエージェントの調査でも、注入下で引数値を読み出す・パッチする研究は見つからなかった（暫定）
source_role / 権限帰属の内部表現	**既に実施**（ただしquotation・negationなど細かい役割区分は未実施）	Ye, Cui, Hadfield-Menell（arXiv:2603.12277 v6、2026-06-27、**ICML 2026採択**）：role probeにより、注入文が模倣した信頼役割と同じ表現空間に入ること、生成前のrole confusionがASRを予測すること（最低分位2%→最高分位70%）を示した。 arxiv + 2 Yu et al.（arXiv:2610.05295 v1、2026-10-04、査読前）：内容・書式を反事実的に入れ替えても役割がAUROC 0.924（Qwen-2.5-7B）で読めることを示し、パッチングまで実施。 arxiv Same Payload, Different Channel（arXiv:2606.00566 v2、2026-08-21、査読前）：チャネル間の信頼の非対称性。非線形に符号化されているため線形probeでは捉えられず、パッチングで回収できる arxiv
引数の連続的選好margin（教師強制の系列対数確率差）	**部分的に実施**	Yu et al.はツール選択をロジット差 m=z_D−z_R で測っている。 arxiv Liaoは目標スコアの感度で測っている。IPI下で正規引数と攻撃引数の系列対数確率差を主要な従属変数にした内部表現研究は見つからなかった
ツール出力内のトークン進行の追跡	**部分的に実施**	Ye et al.は全トークンにrole probeを当てている（付録I）。 arxiv Yu et al.は編集位置としてpre-action、注入スパン、ランダム位置

研究要素	判定	根拠となる論文（公開日・版・査読状況）
		を比べ、前2者ではASRが50.0〜56.3ポイント減るがランダム位置ではほぼ変わらないことを示した。 arxiv 引数アンカー（Tpre/Tpost）に揃えて「引数内容」の進行を追跡した研究は見当たらない
エージェント境界での時間軸追跡	**既に実施（行動・因果のレベル）**	AgentSentry（arXiv:2602.22724 v1、2026-02-26、査読前）：tool-return境界での反事実的な再実行で乗っ取り点を局在化。 arxiv arxiv Dong et al.（arXiv:2608.02657 v2、2026-08-24、査読前）：検出点ごとのprobe。曝露ラベルはAUROC 0.976（Qwen3-8B）だが、最終的な攻撃成功ラベルは0.843にとどまる arxiv
readout × authorityの交互作用で行動選好を説明	**未実施と見られる**	該当研究なし。最も近いのはYe（authority→ASR）とYu（role方向→ツール・引数の行動）だが、内容と権限の交互作用は扱っていない

総合判定：スクープはされていません。 ただし主張の重心を「権限表現が攻撃を予測する」から「引数値の取り出しと、その取り出し元の帰属」に移さないと、査読では「Ye/Yuの同一ツール版」と見なされる危険が高いです。

2. 最も近い競合と、その未解決点

- **Yu et al.「Readable Before Actionable」（2610.05295 v1、2026-10-04）** が最大の競合です。主モデルはQwen-2.5-7Bで、反事実的な役割probe、残差パッチング、AgentDojo上の方向編集を組み合わせています。使ったスイートはSlackとWorkspaceだけで、Banking（送金先引数）は扱っていないことを確認しました。付録U「Tool-Argument arxiv arxiv Injection」では、6ツールの関数呼び出しで役割方向を編集すると「悪意ある引数の使用」が88.2%から12.4%に下がると報告しています。ただしこれは**役割方向の編集**であり、引数値の表現を読み出したりパッチしたりしてはいません（付録本文は未確認）。 arxiv
- **Dong et al.（2608.02657 v2）** は、曝露信号は生成前のassistant近傍で最も強く、ツール呼び出し生成後には弱まると報告しています（strict分割でQwen3-8Bの最良層が0.794）。Banking事例として、推論では副タスクを拒否しているのに arxiv `update_scheduled_transaction` の受取人だけが攻撃者口座になるという同一ツール型の失敗も示しています。ただし、これは定性的な例示にとどまります。 arxiv
- **IterInject（2605.24659 v1、2026-05-23、査読前）** は、中〜後半層の「attention-mediated threshold mechanism」を、3種類の因果介入で検証しています。評価は悪意あるツール呼び出しの有無という二値で、引数レベルの分析ではありません。 arxiv arxiv

3. 現在の負の結果は先行研究で説明でき、むしろ資産になる

- **引数値は事前に保持されず、その場で取り出される。** Wu et al.は「Argument values are pulled from the query on the fly, not from a fixed menu」と述べています。 arxiv 応答生成開始直前の1トークンに受取人のidentityが線形に載っていないことは、この知見と整合的です。
- **束縛情報は実体トークン上にあり、ポインタ的に参照される。** 「Mixing Mechanisms」（arXiv:2510.06182、**ICLR 2026**）は、位置・語彙・反射的（reflexive）機構を組み合わせて束縛された実体を取り出す仕組みを、attention knockoutで追跡しています。「Lookbacks」（arXiv:2505.14685、 arxiv researchgate **ICLR 2026**）は、address/pointerのコピーとQK回路

による逆参照を報告しています。 openreview + 4 どちらも、内容は元の位置に残り、必要な時点で参照されるという描像です。 arxiv nnsight

- **線形probeでは捉えにくい場合がある。** 2606.00566は、信頼チャネルの信号がLlama 3.3-70BとGPT-OSS-120Bで中〜後半層に因果的に存在する一方、非線形に符号化されていると報告しています。 arxiv
- **probeの高AUROCは疑ってかかるべき。** 2610.18408（2026-10-13、査読前）は、会話上の位置と長さだけで標準評価のAUROCが0.91〜0.98に達することを示しました。 arxiv arxiv TF-IDF（約0.53）やランダムラベル（最大0.576）と比べる現在の対照設計は、この点で正しい方向にあります。

解釈： 「モデルは送金先を97.7%で正しく使うのに、生成直前状態からは読めない」という結果は失敗ではありません。**引数内容の計算がどこで行われていないか**を示す、統制の効いた証拠です。これが案Aの出発点になります。

Details

軌道修正案の比較

項目	案A（推奨）：引数スロット時点での取り出し元の因果追跡	案B：行動marginと役割混同の交互作用（簡略版の確認的解析）	案C：内部表現を使った引数単位のprovenanceモニタ	案D：負の結果を中心にした方法論論文
RQ	受取人引数のトークンを生成する時点で、モデルはuser由来とtool由来のどちらの口座を、どの層・どのヘッド経由で取り出すか。取り出し元の決定はauthority（役割知覚）に依存するか	口座スパン上のrole probe値（Ye式のuserness）と教師強制の m_arg に交互作用はあるか	引数トークンから情報源スパンへのattentionとパッチング効果は、AuthorityFlow/PACT型の外部provenanceを内部信号で代替・補完できるか	IPI検出・引数probeは、どの位置・どの対照のもとでなら妥当か
既存研究との差分	Yuは役割方向でツール選択を操作。Wuは引数が操舵できないことを示した。束縛機構研究は注入を扱っていない。これらを結ぶ、**引数値の出所決定の機構**は未着手	YeはauthorityからASRを示したが、引数レベルの連続marginや内容との交互作用は扱っていない	AuthorityFlow/PACTはシステム外部の情報フロー追跡で、内部状態は使っていない	2610.18408・2606.22864と近く、差分は小さい
資産の再利用度	高い：672条件、全36層capture、教師強制、不変bundleがそのまま使える。追加はcapture位置（引数スロット直前、口座トークン上）とパッチングhookだけ	高い	中程度：防御評価のためのAgentDojo走行を追加する必要がある	非常に高い
11月中の実現可能性	中〜高。Qwen3-8B int8でパッチングが難しい場合は、Qwen3-4B fp16などで再現する	高い	低〜中	高い
投稿先候補	ACL 2027（ARR 2027-01-04、公式）、ICML 2027（1月下旬と予測・未公表）、解釈性・安全性系ワークショップ	ワークショップ	セキュリティ系（SaTML 2027は2026-09-29締切で終了済み）	ワークショップ
リスク	int8でのパッチングの実装負担。効果がヘッド単位で局在しない可能性	「Yeの追試」と見なされやすい	AuthorityFlow（2026-11-03）と真っ向から競合する	新規性が弱い

推奨案Aの具体的な11月計画

1. **第1週：位置スイープ。** 既存の672条件で、(a) 口座トークン上（Tpost）、(b) ツール呼び出しJSONの `"recipient": "` 直後、つまり引数スロットの直前（教師強制で作る）、(c) Tend_assistant の3位置について、全36層で受取人identityと情報源（user/tool）のprobeを比較します。ランダムラベル、TF-IDF、Hewitt & Liangのcontrol taskは継続します。口座identityで説明できてしまう問題（96条件診断の懸念）に対しては、口座文字列を固定して出所だけを入れ替えた組を作り、出所probeを評価します。
2. **第2週：因果追跡。** user由来とtool由来の最小対で、口座トークン位置の残差を層ごとに入れ替え、教師強制の m_arg の変化を測ります（Zhang & Nandaに準拠し、logit差を主指標にする）。並行して、引数スロット位置から口座スパンへのattention knockoutを行います。
3. **第3週：IPI条件。** 既存の112条件規模の実走行（資料由来46/48成功、ユーザー指示由来21/64成功）をBankingの引数乗っ取りに拡張します。「取り出し元の決定 × 口座スパン上のrole probe値」で m_arg を説明する回帰を確認的に事前登録します。これは元の β3 の考え方を、測定可能な変数に置き換えたものです。
4. **12月：執筆。** 第1章を負の結果（生成直前には無い）、第2章を取り出し機構（どこで決まるか）、第3章を権限依存性、という構成にします。

Recommendations

中間諮問用 novelty statement（案）

> 既存研究は、注入文が信頼された役割として内部表現されること（Ye et al., ICML 2026）、役割方向の編集がツール選択を変えること（Yu et al., 2026）、引数単位の情報フロー制御が防御として有効であること（AuthorityFlow, PACT）を示してきた。しかし、ツールが同一で受取人などの引数値だけが異なる攻撃において、**モデルが引数値をいつ・どこから取り出し、その取り出し元の決定が権限知覚にどう依存するか**は内部表現のレベルで明らかになっていない。本研究は、引数値が生成直前の状態には線形に保持されていないことを統制付きで示したうえで、引数スロット生成時の取り出し経路を因果的に特定し、それと役割知覚との交互作用によって攻撃引数への選好を説明する。

審査で突かれそうな点と回答案

- **「Ye/Yuと何が違うのか」** → 彼らが扱うのは「誰が話しているか」（役割）とツール選択までで、引数値の出所は扱っていません。Yuの評価もSlackとWorkspaceに限られ、Bankingの受取人には及んでいません。
- **「probeが0.61しか出ないのは手法の失敗では」** → モデル自身の対数確率は97.7%（469/480）で正解しており、情報がモデル内に無いわけではありません。生成直前の1トークンに線形に載っていないだけです。これは引数が操舵できないというWu et al.の結果や、束縛機構研究と整合的で、「どこを測るべきか」を決める予備実験と位置づけます。
- **「AuthorityFlowが出た以上、問題設定に新しさは無いのでは」** → AuthorityFlowはLLMによるシステム外部の情報フロー追跡です。本研究はモデル内部の機構を問うもので、両者は補完関係にあります。2026-11-03公開なので、関連研究として明記して差分を示します。
- **「単一モデル・小規模では一般化できない」** → 全層スイープ、グループ分割、未知系列での評価を行い、可能であれば別サイズのQwen3でも再現します。主張はQwen系列のBankingに限定して述べます。

研究計画書の関連研究セクションで更新すべき点

- **[2]の題目が古い。** 現在の版は「Get my drift? Catching LLM Task Drift with Activation Deltas」（arXiv:2406.00799 v6、2025-03-06）で、旧題「Are arxiv you still on track!?」から改題されています。 arxiv

- **[3]** は ICML 2026採択、最新版 v6（2026-06-27）と明記します。 arxiv letsdatascience
- **[4] IterInject** は v1（2026-05-23）で査読前、cs.LGです。機構解析は付録Eにあり、評価は悪意あるツール呼び出しの有無という二値であることを注記します。 arxiv
- **[5] Dong et al.** は v2（2026-08-24）で、受理は未記載（査読前と扱う）。曝露ラベルと攻撃成功ラベルを区別している点（0.976と0.843）を引用します。 arxiv arxiv
- **[6] AgentSentry** は v1（2026-02-26）、査読前です。 arxiv
- **[7] AutoDojo** は v3（2026-09-28）、査読前です。題目は「AutoDojo: A Generative Benchmark for Evaluating Prompt Injection Defenses in LLM Agents」です。 arxiv
- **追加すべき論文**：Yu et al. 2610.05295（最重要）、AuthorityFlow 2611.04673、PACT 2605.11039、Liao 2607.20827、Influence Is Not Authority 2608.29942、Wu et al. 2605.07990、Same Payload, Different Channel 2606.00566、Prompt-Injection Probes Learn the Conversation 2610.18408、Mixing Mechanisms 2510.06182（ICLR 2026）、Lookbacks 2505.14685（ICLR 2026）、AttriGuard 2603.10749（USENIX Security 2026採択、v2 2026-06-10）、CausalArmor arxiv 2602.07918（ICML 2026）、ToolHijacker（NDSS arxiv 2026、ツール選択攻撃との対比として）。

Caveats

- 2026-11-03公開のAuthorityFlowが示すように、この分野では週単位で新しい論文が出ます。中間諮問の直前にもう一度arXivを確認してください。
- Yu et al. の付録Uの詳細（攻撃する引数の種類、サンプル数、編集位置）は本文で確認できておらず、検索スニペットと本文中の参照にもとづいています。
- 版番号は、PACT（Fan et al.）がarXiv:2605.11039 v1（2026-05-11）、Influence Is Not Authority（Ahad et al.）がarXiv:2608.29942 v1（2026-08-30）です。採択会議も確認できました。AgentDojoは「38th Conference on Neural Information Processing Systems (NeurIPS 2024) Track on Datasets and Benchmarks」（arXiv:2406.13352 v3、2024-11-24、97タスク・629セキュリティテストケース）です。[2]はIEEE SaTML 2025（Copenhagen、2025年4月9〜11日）採択で、pp. 43–67、DOI 10.1109/SaTML64287.2025.00011（IEEE CSDL目次による）です。計画書にはこれらの書誌を記載してください。
- ICML 2027の締切は公式発表前の予測値です。icml.ccにはまだ2027年のcall for papersが出ておらず、第三者サイトの推定も割れています（QAI：アブスト1月22日・論文1月27日、OpenCurious：1月16日・1月22日、ResearchTheta：論文1月28日）。公式に確認できたのはACL 2027のARR締切（2027-01-04）とSaTML 2027の締切（2026-09-29、終了済み）です。 aclweb + 2
- 「注入下で引数値を内部から読み出した研究は無い」という判定は、限られた検索にもとづく暫定的なものです。OpenReview上の非公開投稿は確認できていません。