

進捗報告

- 報告者：大場
- 報告日：2026年9月24日
- 対象期間：9月16日の前回報告以降

1. 実験基盤の整備

前回報告時には未検証だった公開モデルとAgentDojoの接続を実装した。銀行取引環境で、モデルによるツール呼び出し、実行後の成否判定、指定したトークン位置の内部状態取得、および同じ入力に対する正規・攻撃側ツール呼び出しの確率比較まで動作を確認した。実行条件や結果を再確認できるよう、設定、モデルの版、トークン位置、チェックサムを保存する仕組みも整えた。

研究計画では、攻撃内容の読み出し、情報源・役割の読み出し、そこから構成する権限の指標、実際のツール引数の選好を別々に扱う形を明確にした。確認的分析に使う指標と条件は、予備実験・検証データで決めてから固定する。

2. モデル選定試験の結果

AgentDojoの銀行取引タスクを用い、Qwen3-8BとQwen3-4Bを事前に固定した同じ7条件で試した。攻撃のない5条件でユーザータスクに成功したのは、それぞれ3件と2件で、採用基準の4件に届かなかった。ツール実行や正規・攻撃候補の確率計算は動作したが、現時点で主実験のモデルは選定していない。

最初の試験では人手監査に必要な出力の保存が不足したため、記録方法を修正し、新しい実行IDで両モデルを再試験した。再試験の判定は結果集計を見た後の本人監査であり、独立した盲検監査としては扱わない。この少数の選定試験から、攻撃への強さや研究仮説の成否は結論付けない。

3. 現在の判断と次の予定

実験基盤が動くことを確認できたため、Qwen3-8Bと銀行取引環境を**探索的な予備実験に限る暫定構成**とした。主モデル・主ドメインの最終採用ではない。次の実行前に、予備実験の条件、停止・移行基準、選定試験で使った系列を確認的テストから除外する規則を固定する。その後、正規タスクを遂行できる独立した課題系列と、同じツールで引数だけが異なる攻撃条件を十分に作れるか確認する。確認的テストと内部表現の本解析はまだ始めている。