

進捗報告

- 報告者：大場
- 報告日：2026年10月2日
- 対象期間：2026年9月24日の前回報告（commit [ef5907](#)）以降

1. 予備実験の条件を確定

前回のモデル選定試験では採用基準を満たすモデルがなかったため、Qwen3-8BとAgentDojoの銀行取引環境を探索的な予備実験に限る暫定構成として使う。銀行取引タスクを調べ、パスワード変更、請求書、返金、家賃の4系列・6タスクを初回の対象に選んだ。既存系列は予備実験に用い、後の確認的テストには、これらと独立した新しい系列を設計する。

攻撃なし6件、外部データに攻撃文を含む72件、語彙的な対照12件の計90条件を、実行順序・監査方法・停止基準とともに事前に固定した。最初は攻撃なし6件と攻撃文あり12件の計18件を実行し、人手監査を終えて基準を満たした場合だけ残り72件に進む。

2. 実行準備と先行18件の収集

実際のツール利用経路と、同じ入力から正規側・攻撃側のツール引数を比較する診断経路を分けて保存する実行プログラムを整えた。全90条件について、モデルを使わない環境・評価器の対照確認と、固定したtokenizerでの観測位置の確認を完了した。内部状態とAttentionの取得方法はGPUの実測に合わせて固定し、条件付きのパスワード変更タスクについても、実行前に人手判定の根拠を記録した。

凍結した設定で先行18件を実行し、**18件すべてのraw記録を保存できた**。各記録のチェックサムと必須ファイルを検証し、実行段階に技術的停止はなかった。人手監査用の空欄票と、会話・ツール操作・実行後状態を確認する案内を用意した。**監査はまだ始まっていないため、タスク成功率や攻撃成功率は結果として報告しない**。

別工程で予定していた4件の全系列内部状態の詳細取得は、1件を保存した後、2件目で事前に定めたGPUメモリ上限を超えて停止した。残る2件は未実行で、条件の交換や再試行はしていない。先行18件のraw記録は変更していない。

3. 次の作業

先行18件の人手監査を行い、ユーザータスクの達成、攻撃者指定の操作、副作用を分けて確認する。その判定と固定済みの採点・token整合条件を使って、残り72件への移行可否を決める。詳細取得の資源超過については証拠を残し、修正や再取得が必要なら別途判断を記録する。主モデルの正式採用、確認的テスト、内部表現の本解析にはまだ進んでいない。

実行の来歴：先行run prefix [banking-pilot-001](#)、実行code commit [2a709f2](#)。raw記録と監査票はWSLのGit対象外領域に保存し、Gitには大容量の実験データを含めていない。