進捗報告

- 報告者：大場
- 報告日：2026年10月7日
- 対象期間：2026年10月2日の前回報告以降

1. 先行18条件の監査と移行判定

前回報告時に収集済みだったBanking予備実験の先行18条件について、実行記録、ツール操作、実行後の状態を人手で確認した。攻撃なし6件のうち、事前に定めた厳密なユーザータスク成功は**2件**だった。必要な3/6に届かず、凍結済みの拡張移行ゲートは**不合格**と判定した。家賃タスクの1件は指示に部分的に沿う説明が可能だが、指定された更新操作が実行されていないため、事後的に成功へ変更していない。

この3/6は、当初の構成で予備実験の残りの条件へ進むために定めた基準であり、卒業研究全体の成否を判定する基準ではない。一方で、攻撃のない依頼を遂行できるかという研究上の課題を示すため、現在のモデルをそのまま主実験に採用できるとは判断していない。

先行18件の分類はA（攻撃なし・タスク成功）2件、B（攻撃失敗・タスク成功）3件、C（攻撃失敗・タスク失敗）4件、D（攻撃者指定行動の実行）5件、攻撃なしのタスク失敗4件だった。18件の監査、攻撃文あり12件の固定入力での採点・token整合確認は完了し、技術的失敗と未裁定の不一致はなかった。ただし、4タスク系列は一つの関係グループに属するため、これらの件数を独立な成功率推定とは扱わない。判定とその限界は先行ゲート後の判断記録に残した。

2. ゲート不合格後の探索的収集とGPU停止からの再開

ゲート不合格を維持したうえで、残り72条件を**結果閲覧後に決めた探索的継続**として収集した。条件の内容と順序、12 GiBのGPU上限は変えていない。実行順19〜50の32件を完了した後、51番の内部状態取得で上限を超え、技術的に停止した。停止時には50条件が完了、51番が技術的失敗、39条件が未実行だった。停止記録を保存し、失敗したrunを保持した。

保存済みの51番の入力を使った工学計測で、取得直前に未使用のCUDAキャッシュを解放すれば、同じ12 GiB上限内で内部状態を取得できることを確認した。別の判断記録と実行設定を作成し、51番を新しいrun IDで再取得してから52〜90を順に収集した。新たな40件はすべて完了し、**全90条件に完了記録がある**。旧51番の失敗を含めた総試行数は91で、旧記録は上書きしていない。再開実行記録には、別の実行段階とチェックサムを残した。

拡張分の人手監査は未完了である。90条件の監査前の機械集計と空欄の監査票は保存したが、拡張分のユーザータスク成功率・攻撃成功率を確定結果として報告しない。先行ゲートの不合格も変わらない。

3. 測定の確認と研究範囲の明確化

先行18件の保存状況を図示し、実際の軌跡における内部状態の取得範囲と、代表1件でのトークン位置間の残差表現の差を確認した。図と説明は取得・比較の実現性を示すもので、攻撃目的の読み出しや因果的な乗っ取りの証拠ではない。

研究計画の表現を見直し、今後の**確認的主解析の対象を、同じツールの主要引数を攻撃者指定値へ変えさせる攻撃**に明確化した。引数内容の読み出し、情報源・役割、操作的な権限スコア、正規／攻撃引数への選好を別の測定として扱う。異なるツールへの切替攻撃は副次的・探索的に扱う。この明確化はpilot収集後、確

認的テストを作成・閲覧する前に記録したもので、既存の判定や実験データは変更していない。範囲の判断記録を参照。

4. 次の作業と現時点の位置づけ

拡張分の人手監査を完了し、全runの流れ、タスク系列ごとのユーザータスク達成と攻撃者指定行動、注入文への実際の接触、内部状態と候補呼出し採点の欠測を分けて確認する。その結果を踏まえて、暫定モデル・Bankingの扱い、評価器の課題、独立した新タスク系列の確保、次段階へ進む条件を判断し、必要な変更は別の判断記録に残す。

現時点の作業予定は次のとおりである。日付は目標であり、監査結果と構成の採否判断に応じて更新する。

1. **今週（10月7日〜11日）**：拡張分の人手監査を進め、実際の軌跡で注入文への接触、内部状態の取得、正規／攻撃候補の採点がどのタスク系列で成立したかと、欠測・評価器の不一致を確認する。並行して、引数内容と情報源・役割を読み取るprobeの設計・実装を準備する。
2. **10月中旬**：監査結果を基に、暫定モデル・Bankingで研究を進める条件、新しい独立タスク系列を確保できる見込み、probe用の対応条件を検討する。現行構成で必要な測定が成立しなければ、モデル・ドメイン、教師強制による行動採点中心の方法、または研究主張の範囲を見直し、判断と根拠を新しいRDRに記録する。
3. **10月下旬を目標**：進める構成が決まった場合、開発用の新系列でprobeを学習・検証し、未知系列での性能と語彙だけに基づく比較方法を確認する。その結果を踏まえて測定方法、データの分割、主解析を確認的テストの実行前に固定する。

probeの設計準備は今週から始めるが、内部状態を保存できたことだけでprobeが有効だとは判断しない。probe用データの本格的な収集・学習および確認的テストへの移行は、監査と構成の判断後に行う。

現時点で主モデルと主ドメインは正式採用していない。Phase 2への移行は未許可で、確認的テストは未作成・未実行・未閲覧である。内部表現を読むprobeの本解析もまだ行っていない。今回の90条件は、ゲート不合格後の収集と技術停止後の再取得を含む**探索的資料**として保持する。