

卒業研究計画案

研究題目

仮題

Indirect Prompt Injectionを受けたLLMエージェントにおける目的表現の時系列的・幾何学的解析

英題

Temporal and Geometric Analysis of Goal-Representation Takeover in LLM Agents under Indirect Prompt Injection

1. 研究背景と問題意識

大規模言語モデル（LLM）は、外部のメール、ファイル、Webページなどを読み取り、必要に応じてツールを呼び出すAIエージェントとして利用されている。しかし、外部データに悪意ある命令が埋め込まれていると、本来は処理対象である文章を命令として解釈し、不正な行動を実行する可能性がある。この攻撃は Indirect Prompt Injection と呼ばれる。

AgentDojoは、メール、オンラインバンキング、旅行予約などの環境で、エージェントの Prompt Injection 攻撃と防御を評価するベンチマークである [1]。既存研究では、主に攻撃成功率、ユーザータスク成功率、攻撃検知性能などの外部的な結果が評価されてきた。

内部状態を利用する研究として、Are you still on track!?は、外部データを読む前後の Activation 差分から、ユーザーの元のタスクから逸脱する Task Drift を線形分類器で検出できることを示した [2]。Prompt Injection as Role Confusion は、モデルが入力元のラベルだけでなく文章の書き方から「誰の発言か」を内部的に推定し、Role の混同が生成開始前から攻撃成功と関連することを報告している [3]。また IterInject は、攻撃文への Attention が中後層で増幅される閾値的な機構と、その機構に対する介入結果を報告している [4]。

一方、ツール利用型エージェントが攻撃文を読んでから行動を選択するまでに、ユーザー目的と攻撃者目的に関する内部表現が、どの層・処理段階でどのように変化するかは十分に明らかになっていない。本研究では、この過程を二つの目的表現の競合として捉え、攻撃者側の表現が後続行動と結びつく候補時点を Takeover Point と呼ぶ。ただし、目的が完全に置き換わることは前提とせず、観測上の候補として慎重に扱う。

2. 研究目的と Research Question

本研究の目的は、Indirect Prompt Injectionを受けたAIエージェントについて、外部データを読み取ってからツールを選択するまでの内部状態を時系列で観測し、ユーザー目的と攻撃者目的に関する情報が、最終行動にどのように結び付くかを明らかにすることである。Task Driftや攻撃成功の検知は比較用ベースラインとし、主眼を表現の時間的变化に置く。

次の Research Question を設定する。

1. 正常な単一目的実行から構成した readout によって、ユーザー目的と攻撃者目的に関する情報を各層・処理段階から別々に読み出せるか。

2. 二つの目的readoutの変化は、後続する攻撃ツールと正規ツールのLogit差と関連し、その関係はどの層・処理段階で明瞭になるか。
3. 攻撃を受け入れやすい条件と抵抗する条件の差は、目的readout、Role readout、攻撃文へのAttentionのどれによって安定して説明できるか。
4. 十分な対応事例が得られた場合、候補時点へのActivation Patchingによって攻撃ツールの選択傾向を弱められるか。

本研究の中心的新規性は、Prompt Injectionを単一時点の検知問題として扱うのではなく、目的内容、入力Role、Attentionおよび行動候補の関係を、エージェントの複数処理段階にわたって比較する点にある。

3. 実験対象と範囲

内部状態を取得できる2B～8B程度の公開WeightのInstruction Modelを用い、単一モデル・単一ドメインから開始する。対象ドメインは、AgentDojoに含まれるメール、旅行予約、金融、文書処理などから一つを選ぶ。

主な攻撃経路は、ツールが返す外部データに攻撃命令を埋め込むIndirect Prompt Injectionとする。各実行は次の四群に分類する。

- 群A：攻撃文がなく、ユーザータスクに成功
- 群B：攻撃文があり、攻撃には失敗するがユーザータスクに成功
- 群C：攻撃文があり、攻撃とユーザータスクの両方に失敗
- 群D：攻撃者が指定した不正な行動を実行（ユーザータスク成功・失敗を別途記録）

主に群Bと群Dを比較し、「攻撃内容を認識したこと」と「攻撃に従ったこと」の分離を試みる。

4. 成功・失敗条件の構成

同じ入力とモデルから計算される内部状態とLogitは、確率的生成で最初の異なるトークンが選ばれるまでは原則として同一である。そのため、同じ入力を乱数seedだけ変えて得た成功実行と失敗実行は、分岐前の内部状態差を説明する主比較には用いない。

主解析では、ユーザー目的と攻撃者目的を固定し、ユーザー指示と攻撃文の言い換え、攻撃文の配置、無害な周辺文章、書式などを制御して変化させた、意味的に対応する入力変種を作る。モデルを固定し、原則としてgreedy decodingまたはtemperature 0で実行する。攻撃ツールを選ばない入力変種をResistant、攻撃ツールを選ぶ入力変種をSusceptibleとする。文長、主要語彙、命令形式および行動決定点を可能な範囲で対応させ、特定の文面による差は複数の入力変種と対照条件で評価する。

二値のツール選択だけでなく、ツール選択直前の攻撃ツールと正規ツールのLogit差を、攻撃行動への連続的な選択傾向として用いる。

$$m = \text{Logit}(\text{attack tool}) - \text{Logit}(\text{legitimate tool})$$

ツール名が複数トークンの場合は、ツール呼び出し全体の系列Log probabilityなどを比較する。確率的生成は、個々の成功・失敗実行の内部状態比較ではなく、各入力条件のAttack Success Rateを推定する補助評価に用いる。攻撃強度を変える場合は、同一条件の反復ではなく独立した実験要因として扱う。

5. 取得する内部情報と処理段階

各実行について、Transformer各層のResidual Stream、攻撃文などへのAttention、次のトークンおよびツールに対するLogitを保存する。また、外部データを読む前後のActivation差分をTask Drift検知のベースライン

に使用する。Attentionの大きさだけから判断理由を断定せず、補助指標として扱う。

内部状態は、少なくとも次の処理段階に対応付ける。

1. ユーザー指示を読んだ直後
2. 外部ツールを呼び出す直前
3. ツール出力を読んだ直後
4. 次の行動を決定する直前
5. 攻撃または正規ツールを呼び出す直前

各処理段階では、原則として、その時点までの入力系列を処理し、次の生成またはツール選択を開始する直前の系列末尾tokenにおけるResidual Streamを代表表現として取得する。入力形式の違いによる影響を抑えるため、可能な場合は各入力系列の末尾を同一の区切りtokenまたはAssistant生成開始位置に統一し、使用したtoken位置とtoken IDを記録する。末尾tokenだけでは結果が安定しない場合は、末尾数tokenの平均表現または目的に対応するtoken位置を用いた解析を感度分析として追加する。

各層・処理段階の内部状態を時系列の軌跡として扱い、正常例、Resistant、Susceptibleで比較する。

6. 目的readoutの構成

「モデルが目的を保持しているか」は直接観測できないため、目的への適合度を単一の正解ラベルとして与えず、次の三要素に分解する。

- 目的内容readout：要約、送信、削除など、特定の行動目的に関する情報が表現されているか
- Role readout：その目的を含む指示がUser由来かTool由来かという情報が表現されているか
- 行動候補：その目的に対応するツールまたは行動が次の選択候補として強まっているか

目的内容readoutの教師データには、Prompt Injectionの成否ではなく、目的が一つだけ明示された正常な単一目的実行を用いる。正解ラベルは、タスク生成時に指定した目的、入力Role、文章形式からプログラムの付与し、一部を人手で確認する。単なる語彙の検出を避けるため、同じ目的内容について、正規のUser命令、Tool出力内の命令、説明、引用、否定・禁止、過去の行動の記述を用意する。

目的内容readoutは、要約、送信、削除、予定登録など、実験前に定めた目的カテゴリごとのMulti-label線形Probeとして構成する。各実行について、ユーザー目的に対応するカテゴリ g_{user} と攻撃者目的に対応するカテゴリ g_{attack} を特定し、各層・処理段階における較正済み出力スコア $s_{g_{\text{user}}}(t, l)$ および $s_{g_{\text{attack}}}(t, l)$ を追跡する。ユーザー目的と攻撃者目的は同時に表現され得るため、一方だけを選ばせる多クラス分類にはしない。

スコアは共通の検証データ上で確率較正または標準化し、生の出力値を直接比較しない。また、このスコアは各目的内容が内部状態から読み出せる程度を示すものであり、その目的の入力元、権限の認識、行動への採用を単独で示すものではない。そのため、Role readoutおよびツール選択のLogit差と併せて解釈する。ユーザー目的と攻撃者目的が同じカテゴリに属する条件は、目的内容readoutだけでは両者を区別できないため、主比較から除外するか、同一カテゴリ条件として別に解析する。攻撃成功と最終的なツール選択は目的内容readoutの教師ラベルには使わず、学習後の外部評価に用いる。

7. 解析方法と対照条件

まず、PCAなどによる探索的可視化と、Task Driftおよび攻撃成功を予測する線形Probeを既存研究との比較用ベースラインとして実施する。主解析では、正常な単一目的実行と、同じ目的語彙を含む説明・引用・否定などの対照実行から目的方向を構成し、各層・処理段階における二つの目的readoutの変化を追跡する。

主な統計的比較は、攻撃文を読む前後の標準化された攻撃者目的readoutの変化量と、ツール選択直前の攻撃ツール・正規ツール間のLogit差との関連とする。群Bと群Dの二値比較は副次解析とし、同じ層・時点におけるRole readoutおよびAttention指標と説明力を比較する。readoutの逆転だけで目的が置き換わったとは判断せず、複数指標と後続行動との対応からTakeover Point候補を示す。

表面的特徴による説明を除くため、無害な命令文、同じ攻撃語彙を含む説明文、長さを揃えた無害文、異なる言い回しの攻撃を対照条件に含める。また、タスクまたは攻撃テンプレート単位でデータを分割し、未知タスク・未知攻撃で評価する。

十分な対応事例と安定したreadoutが得られた場合のみ、発展課題としてActivation Patchingを行う。意味的に対応するResistantのActivationをSusceptibleの候補時点へ移植し、攻撃ツールと正規ツールのLogit差が低下するかを、無関係な位置・層・donorを用いた対照介入と比較する。

8. 実験規模と統計計画

単一モデル・単一ドメインについて、内部状態を保存する主実験を約1,400実行とする。暫定的な内訳は次のとおりである。

- 目的readoutの教師・対照データ：約480実行
- Prompt Injection評価：約800実行
- 正常実行ベースライン：約100実行

Prompt Injection評価は、例えば20種類のユーザータスク、4種類の攻撃目的またはテンプレート、各組合せ10種類の意味的な入力変種で構成する。群Bと群Dをそれぞれ最低100実行、目標150実行以上確保し、ResistantとSusceptibleの両方が得られる意味的な対応条件を最低20組、目標30組以上確保する。

確率的生成は、Logit差が0に近い条件と各タスク・攻撃の代表条件を優先し、temperature、top-pなどを固定して各10回程度行う。この補助評価では原則として全Activationを保存しない。最初に100～150実行のPilot実験を行い、攻撃成功率、入力変種間の分散、計算時間、保存容量を推定した上で、入力変種数と反復数を調整する。

学習・検証・テストは暫定的に60%、20%、20%とするが、実行単位で無作為分割せず、同じタスク・攻撃条件に属する入力変種、確率的反復、近い言い換えを同じ分割にまとめる。統計解析では、同一タスク・攻撃条件内の入力変種を完全に独立とはみなさず、条件単位のBootstrapまたは変量効果モデルを用いる。効果量と95%信頼区間を報告し、層・時点・指標の多重比較にはFalse Discovery Rateの制御を適用する。最終的な標本数と解析方法はPilot結果に基づいて確定する。

9. 期待される成果と達成基準

攻撃失敗例でも攻撃内容自体は読み出せる一方、攻撃を受け入れやすい条件では、攻撃者目的readout、Role readout、Attentionまたは行動候補に異なる時間的変化が現れると予想する。本研究により、最終的な攻撃成否だけでなく、不正なツール選択に至る前の内部的兆候と、その候補層・時点を示すことを目指す。

卒業研究としての達成基準を次のように設定する。

必須達成目標

- 公開LLMを用いた単一ドメインのツール利用型エージェントを構築する
- 正常例、攻撃失敗例、攻撃成功例の内部状態を取得する
- 層・処理段階ごとの内部状態変化を比較する

- Task Driftまたは攻撃成功の検知Probeをベースラインとして再現・評価する

標準達成目標

- 正常な単一目的実行と対照条件から目的readoutを構成する
- 目的readoutの時間的変化とツール選択直前のLogit差との関連を定量化する
- Role readoutおよびAttention指標と比較してTakeover Point候補を示す

発展達成目標

- 意味的に対応したActivation Patchingによって候補状態の因果的寄与を検証する
- 別モデルまたは別ドメインで小規模な一般化評価を行う

10. 研究工程

1. 公開Instruction Modelと単一ドメインを選定し、内部状態を保存できる最小エージェント環境を構築する。
2. 100～150実行のPilotによって攻撃成否、計算時間、保存容量を確認し、本実験規模を確定する。
3. 正常実行と意味的に対応するPrompt Injection入力変種を収集し、外部挙動とLogit差を評価する。
4. Task Drift検知を再現した後、目的内容、Role、行動候補のreadoutを学習・評価する。
5. 各層・処理段階の時間的変化、対照条件、未知タスク・未知攻撃を解析する。
6. 条件が整った場合のみActivation Patchingを行い、結果を卒業論文としてまとめる。

11. リスクと代替案

- 目的方向を明確に抽出できない場合は、単一方向ではなく低次元部分空間、または具体的なツール選択表現を解析する。
- 攻撃成功例が不足する場合は、事前評価した攻撃テンプレートや強度を独立要因として追加し、単一ドメイン内で条件数を確保する。
- AgentDojoと内部状態取得基盤の接続が難しい場合は、AgentDojoのタスク構造を参考に独自の最小環境を構築する。
- Activation Patchingで効果が得られない場合も、時系列的なreadout解析を主成果とし、介入結果は発展的・否定的結果として扱う。

参考文献

- [1] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, and F. Tramèr, "[AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents](#)," arXiv:2406.13352, 2024.
- [2] S. Abdelnabi, A. Fay, G. Cherubin, A. Salem, M. Fritz, and A. Paverd, "[Are you still on track!? Catching LLM Task Drift with Activations](#)," arXiv:2406.00799v3, 2024.
- [3] C. Ye, J. Cui, and D. Hadfield-Menell, "[Prompt Injection as Role Confusion](#)," arXiv:2603.12277, 2026.
- [4] Z. Chen, J. Chen, L. Luo, K. Xu, X. Huang, T. Sun, and X. Jiang, "[IterInject: Indirect Prompt Injection Against LLM Agents via Feedback-Guided Iterative Optimization](#)," arXiv:2605.24659, 2026.