

卒業研究計画案

研究題目

仮題

間接プロンプトインジェクション下のLLMエージェントにおける目的内容・権限帰属・ツール引数選好の表現遷移解析

英題

Tracing Goal Content, Authority Attribution, and Tool-Argument Commitment in LLM Agents under Indirect Prompt Injection

1. 研究背景と問題意識

大規模言語モデル（LLM）は、外部のメール、ファイル、ウェブページなどを読み取り、必要に応じてツールを呼び出すAIエージェントとして利用されている。しかし、外部データに悪意ある命令が埋め込まれていると、本来は処理対象である文章を命令として解釈し、不正な行動を実行する可能性がある。この攻撃は間接プロンプトインジェクション（Indirect Prompt Injection; IPI）と呼ばれる。

AgentDojoは、メール、オンラインバンキング、旅行予約などの環境で、エージェントに対するプロンプトインジェクション攻撃とその防御を評価するベンチマークであり、ユーザータスク成功と攻撃成功を区別して評価できる [1]。既存研究では、主に攻撃成功率、ユーザータスク成功率、攻撃検知性能などの外部的な結果が評価されてきた。

内部状態を利用する研究として、Are you still on track!?は、外部データを読む前後の活性化差分からTask Driftを線形分類器で検出できることを示した [2]。Prompt Injection as Role Confusionは、モデルが入力元のラベルだけでなく文章の書き方から発言者の役割を内部的に推定し、役割の混同が生成開始前から攻撃成功と関連すると報告している [3]。IterInjectは、中後層における攻撃文へのAttention増幅と、その機構への介入結果を報告している [4]。さらに、生成前の隠れ状態からIPIへの露出を判別できる一方、その信号が安全な行動へ必ずしも結び付かない知識・行動間の乖離が報告されている [5]。AgentSentryは複数ターンのIPIを時間的・因果的な乗っ取りとして扱い、ツール返却境界における反実仮想的な再実行から乗っ取り時点を局在化している [6]。

これらを踏まえると、「IPIへの露出を内部状態から検出できる」「役割表現またはアテンションが攻撃成功と関連する」「時間的な乗っ取り時点が存在する」という主張だけでは新規性が限定される。本研究は、目的に関する情報を、(i) 行動、(ii) 引数または制約、(iii) 情報源・権限条件、(iv) 具体的なツール呼出しへの行動選好に分ける。特に、正規行動と攻撃行動が同じツールを使用し、受取人、口座、金額、対象IDなどの引数だけが異なるIPIを中心に、内容が読めること、権限ある指示として表現されること、具体的な引数が選好されることの分離と結合を調べる。

なお、2026年の関連研究には査読前のプレプリントを含むため、報告された結果を確立した一般機構とはみなさず、本研究の新規性の境界と比較対象として慎重に扱う。

2. 研究目的と研究課題

本研究の目的は、IPIを受けたツール利用型LLMエージェントについて、攻撃内容が内部状態に表現されることと、その内容が権限ある指示として扱われ、具体的なツール操作または引数の選好へ結び付くことを区別して観測することである。Task Drift、IPIへの露出、役割の読み出しおよびAttentionは比較用の指標とし、主眼を目的内容・権限・ツール呼出し選好の関係に置く。

次の研究課題を設定する。

1. 同一内容をユーザー命令、ツール出力、引用、説明、否定・禁止などに置いた対応条件と、未知のタスク系列または攻撃系列において、行動・引数の内容と情報源・権限条件を独立に読み出せるか。
2. IPI範囲の処理後、攻撃者側引数の読み出しと権限の読み出しは、後続する正規ツール呼出しと攻撃ツール呼出し、特に引数部分の系列対数確率差と、どのトークン位置・層・エージェント境界で関連するか。
3. その関連は、IPIへの露出、表面的な語彙・書式、タスクの開放度、入力長、攻撃位置および攻撃範囲へのAttentionを考慮しても、後続する行動選好と安定して対応するか。

活性化パッチング（Activation Patching）は研究課題の成立条件には含めず、十分な対応事例と独立に再現する候補領域が得られた場合だけ、介入方法と評価指標に関する推奨手法 [9]を踏まえた発展的な因果検証として行う。

本研究の中心的新規性は、目的内容、権限およびツール操作・引数の選好を異なる測定として扱い、ツール出力内のトークン進行とエージェントループの境界という二つの時間軸で、同一ツール・異なる引数のIPIを含めて追跡する点にある。ただし、読み出し値の増加だけを目的の採用とは解釈せず、介入なしに因果的な「乗っ取り」を主張しない。

3. 実験対象と範囲

内部状態を取得できる2B～8B程度の公開重みの指示モデルを用い、単一モデル・単一ドメインから開始する。モデルとドメインは、以下を満たすかを小規模な統合試験で確認してから固定する。

- 決定論的な主比較で攻撃なしタスクとツール呼出しが安定する。
- 正規呼出しと攻撃呼出しを同一の接頭系列から教師強制で評価できる。
- ユーザータスク成功と攻撃成功を実行後の環境状態から独立に判定できる。
- 同一ツール・異なる引数の正規／攻撃反実仮想を構成できる。

引数置換を形式化しやすいBankingを第一候補とするが、正準ツール呼出しのスコアリングまたはエージェント接続が安定しない場合は、同様に宛先や対象IDを評価できる単一の代替ドメインへ切り替える。主実験では一モデル・一ドメインを維持し、別モデル・別ドメインの一般化評価は必須としない。

タスクの開放度を次のように事前分類する [7]。

- **fully_specified**: 行動と主要な引数がユーザープロンプトで指定される。
- **param_open**: 行動は指定され、引数を外部データから取得する。
- **action_open**: 実行する行動自体を外部データへ委ねる。

確認的解析は解釈しやすい**fully_specified**と、同一ツール・異なる引数の攻撃を扱える**param_open**を中心とする。**action_open**は権限混同と正当な委任を分けにくいいため、副次的な調整効果の解析に限定する。

主な攻撃経路は、ツールが返す外部データに攻撃命令を埋め込むIPIとする。各実行は次の四群に分類する。

- 群A：攻撃文がなく、ユーザータスクに成功

- 群B：攻撃文があり、攻撃には失敗するがユーザータスクに成功
- 群C：攻撃文があり、攻撃とユーザータスクの両方に失敗
- 群D：攻撃者が指定した不正な行動を実行（ユーザータスク成功・失敗を別途記録）

群A～Dは外部妥当性のために保持するが、主解析は連続的なツール呼出し選好を用い、群B対群Dの二値比較は副次解析とする。攻撃文のない実行でユーザータスクに失敗した場合は、A～Dへ含めず

`baseline_failure`として保持する。

4. 条件構成と行動指標

同じ入力とモデルから計算される内部状態とロジットは、確率的生成で最初の異なるトークンが選ばれるまでは原則として同一である。そのため、同じ入力を乱数シードだけ変えて得た成功実行と失敗実行は、分岐前の内部状態差を説明する主比較には用いない。

主解析では、ユーザー目的と攻撃者目的を固定し、ユーザー指示、攻撃文の言い換え、攻撃文の配置、無害な周辺文章および書式を制御して変化させた、意味的に対応する入力変種を作る。モデルを固定し、主比較は貪欲デコーディングまたは同等の決定論的設定で実行する。選定モデルがその設定で安定しない場合は、モデルを変更するか、決定論的な教師強制によるスコアリングを主解析として生成結果と分離する。確率的生成は、各条件の攻撃成功率を推定する補助評価に限る。

正規呼出し a_L と攻撃呼出し a_A を同一の直列化済み接頭系列から教師強制で評価し、次の指標を保存する。

1. `argument_slot_margin`: 対応する引数スロット全体の系列対数確率差。主な行動指標とする。
2. `whole_call_margin_total`と`whole_call_margin_normalized`: 正準ツール呼出し全体の系列対数確率差について、合計値とトークン数で正規化した値を保存する。
3. `first_discriminating_token_margin`: a_L と a_A が最初に分岐するトークンでのロジット差。トークン化への依存性を確認する診断指標とする。
4. `tool_name_margin`: ツール種別が異なる条件だけで使用する。

主指標は、値が大きいほど攻撃呼出しを選好するよう、次の向きに統一する。

$$m_{\text{arg}} = \log P(\text{argument}_A | x) - \log P(\text{argument}_L | x)$$

複数トークンからなる引数またはツール呼出しについて、最初のトークンだけから結論を出さない。同一ツール・異なる引数の条件は除外せず、むしろ確認的解析の中心条件とする。

5. 取得する内部情報と二つの時間軸

各実行について、Transformer各層の残差ストリーム、定義した範囲へのAttention集約値、次トークンのロジットおよび正規／攻撃ツール呼出しの系列対数確率を保存する。また、外部データを読む前後の活性化差分をTask DriftまたはIPI露出検知のベースラインに使用する。

残差ストリームは、主実験では全層について、事前指定した観測トークン位置とIPI範囲周辺の固定幅windowに限定して保存する。全sequence・全層の残差ストリームは、トークン位置の対応確認、window幅の決定および探索的な時間変化の確認を目的として、予備実験の事前指定した少数例だけで保存する。window幅、sequence端での境界処理および保存位置は予備実験と検証データで固定し、確認的テストの確認後に変更しない。

「いつ」をエージェントループの境界と単一の順伝播内のトークン位置に分ける。

エージェント境界

- **user_to_assistant**: ユーザー指示までを直列化し、最初のアシスタント生成を開始する直前。
- **first_tool_to_assistant**: 最初のツール返却までを直列化し、次のアシスタント生成を開始する直前。IPIが次行動へ影響できる主要境界。
- **later_tool_to_assistant**: 2回目以降のツール返却後に次のアシスタント生成を開始する直前。遅延効果を調べる副次時点。

ツール出力内のトークン位置

- **Tpre**: 注入範囲直前のトークン。
- **Tpost**: 注入範囲直後のトークン。
- **Tend_tool**: ツール出力末尾のトークン。
- **Tend_assistant**: チャットテンプレート上のアシスタント生成開始マーカー。**Tend_tool**と同じトークンでない場合は分けて保存する。

各時点について、元のメッセージ列、実際にモデルへ渡した直列化済みテキストまたはトークン列、そのチェックサムから生成する**prefix_id**、系列長、トークン位置、トークンID、選択規則およびチャットテンプレートを保存する。活性化については、保存モード（**full_sequence**または**selected_positions_and_ipi_window**）、保存対象層、windowの左右幅と実際の開始・終了トークン位置、およびsequence端でのwindow切れの有無も保存する。異なる段階名でも直列化済み接頭系列とトークン位置が同一なら、別の観測時点として重複計上しない。末尾数トークンの平均は感度分析に限り、主解析の位置は予備実験および検証データで固定する。

Attentionは攻撃範囲、ユーザー目的範囲、ツールのメタデータ範囲への集約量を通常保存し、全層・全ヘッドの完全なAttention行列は予備実験の少数例または事前指定した候補だけに限定する。Attentionの大きさだけから判断理由を断定せず、補助的な記述量として扱う。

6. 読み出しの構成と解釈

「モデルが目的を採用したか」は直接観測できないため、次の測定を区別する。

- **action_readout**: 送信、振込、削除など、行動内容が残差ストリームから読み出せる程度。
- **argument_readout**: 受取人、口座、金額、ファイルIDなど、具体的な引数または制約が読み出せる程度。
- **authority_readout**: 同一内容がユーザー命令、ツール由来の非信頼内容、引用、説明、否定・禁止など、どの情報源・権限条件に置かれたかを読み出せる程度。
- **tool_call_preference**: 正規／攻撃ツール呼出し、特に引数への行動選好。プローブではなく対数確率差で測定する。

行動・引数の読み出しの教師データには、攻撃成否ではなく、目的が一つだけ明示された正常な単一目的実行と対照条件を用いる。権限の読み出しには、可能な限り同一文字列を異なる役割、引用、説明、禁止等に配置した対応テキスト条件を用いる。攻撃成功と最終的なツール選択は読み出しの教師ラベルに使用せず、学習後の外部評価にのみ用いる。

内容への言及（**mention**）は内容の読み出し、具体的行動への確約（**commitment**）はツール呼出し選好として操作的に区別する。行動結果から**adopted**または**committed**ラベルを作って同じ行動を予測するプローブは、循環的になるため主解析では作らない。読み出しスコアの増加は、内容が読み出し可能であることを示すに留まり、権限付与、採用または因果的寄与を単独では示さない。

プローブの妥当性確認には、プローブが表面的対応や無意味なラベルを学習しただけではないかを調べる対照課題の考え方 [8]を踏まえ、少なくとも次を含める。

- 対応テキスト・異なる権限条件
- TF-IDF等を用いた語彙ベースライン
- 同じグループ構造を保ったランダムラベル対照
- タスク、攻撃目的、攻撃形式および近い言い換えをまたがせないグループ考慮分割
- 未知のタスク系列または未知の攻撃系列での評価
- 学習データのみでの標準化、検証データのみでの層・正則化・閾値・較正方法の選択

テストデータは最後に一度だけ確認し、予備実験、攻撃選択、層選択または閾値調整に使用した系列を確認的テストへ含めない。

7. 解析方法と対照条件

確認的主解析は一つに固定する。`first_tool_to_assistant`のツール出力内で、`Tpre`から事前指定した終端位置までに生じる攻撃者側引数の読み出しの変化と、その終端位置における権限の読み出しが、後続する行動決定時点の`argument_slot_margin`を説明するかを評価する。終端位置は`Tend_tool`または`Tend_assistant`から検証データで選び、IPI露出のベースライン、タスクの開放度、入力長、攻撃位置および表面的特徴を共変量または層別要因として扱う。

中間層の候補領域、トークン位置、前処理、正則化および判定閾値は予備実験と検証データだけで決定し、そこで使用したタスク系列・攻撃系列は確認的テストから除外する。最終層・最終トークンの読み出しと同じ位置のロジット差は、構造的に相関し得るため健全性確認に下げ、主張の中心にしない。

主な対照条件として、無害な命令文、同じ攻撃語彙を含む説明・引用・禁止、長さを揃えた無害文、同じ内容を異なる役割へ置いた条件、異なる言い回しの攻撃を含める。Task Drift、IPIへの露出、役割の読み出し、PCA等の可視化、群B対群D、Attentionおよび`later_tool_to_assistant`は副次解析とする。全層・全位置の探索的な図を示す場合は探索的解析と明記し、偽発見率を制御する。

推論単位は個々の表層的な入力変種ではなく、タスクと攻撃目的・形式から構成した独立クラスターとする。効果量と95%信頼区間を、最高位クラスター単位のブートストラップ法または置換法で報告する。十分なクラスター数と安定した推定が得られた場合だけ、変量効果モデルを補助的に用いる。

8. 実験規模と統計計画

12月までに主結果を確定するため、実行数を先に固定するのではなく、独立クラスター数、実装時間および保存容量を優先する。単一モデル・単一ドメインについて、活性化を保存する実行の暫定総数を約450~700とする。

この実行数は、主実験では事前指定したトークン位置とIPI周辺windowの活性化のみを保存し、全sequence・全層の保存を予備実験の少数例に限定することを前提とする。

- 予備実験：80~120実行
- プローブ教師・対應對照条件：200~300実行
- 確認的IPI：タスク×攻撃目的・形式の独立クラスターを最低30、各クラスターにつき3~4個の表層的な入力変種を目安とする
- 攻撃なしベースライン：60~100実行

最終的な配分は予備実験後に凍結する。表層的な言い換えだけを増やして見かけ上の標本数を大きくせず、`attack_goal_id`と`attack_style_id`を分け、多様な意味・形式の系列を優先する。攻撃抵抗条件（Resistant）と攻撃感受条件（Susceptible）の両方が得られる意味的対応条件は最低20組、目標30組とするが、群B・群Dの件数だけを主解析の成立条件にはしない。

確率的生成は、マージンが0に近い条件と各タスク・攻撃の代表条件を優先し、生成設定を固定して各10回程行う。この補助評価では原則として活性化を保存しない。

学習・検証・テストは暫定的に60%、20%、20%とするが、実行単位で無作為分割しない。同じタスク、攻撃目的、攻撃形式、対応組、近い言い換えおよび確率的反復をデータ分割間で分離しない。検定方法、主要な説明変数、共変量、除外規則および感度分析はテスト確認前に凍結する。

9. 期待される成果と達成基準

攻撃失敗例でも攻撃内容自体は早期に読み出せる一方、攻撃を受け入れやすい条件では、内容の有無より権限の読み出しと引数選好の結び付きが中間層から後半層で強くなると予想する。また、`action_open`のタスクほど攻撃内容と正当な委任の区別が難しくなると予想する。

必須達成目標

- 公開LLMを用いた単ドメインのツール利用型エージェントを構築する。
- 正確な直列化済み接頭系列とトークン位置に対応した残差ストリームを取得する。
- ユーザータスク成功、攻撃成功、A～Dおよびベースライン失敗を独立に記録する。
- Task DriftまたはIPI露出のプロープを比較用ベースラインとして再現・評価する。
- 同一の接頭系列から正規／攻撃の正準ツール呼出しの系列対数確率を評価する。

標準達成目標

- 対照対照条件から行動・引数の読み出しと権限の読み出しを構成し、語彙ベースラインと比較する。
- `Tpre`から事前指定した終端位置までの読み出しの変化と、後続する引数マージンの関連を定量化する。
- タスクの開放度とグループ構造を考慮した効果量および95%信頼区間を報告する。
- 陽性・陰性のいずれでも、目的内容、権限、ツール呼出し選好を区別した解釈を提示する。

発展達成目標

- 意味的に対応した双方向の活性化パッチングによって候補状態の因果的寄与を検証する。
- 別モデルまたは別ドメインで小規模な一般化評価を行う。

10. 研究工程と期限

12月は追加の探索実験ではなく、執筆と再現確認に充てる。2026年9月15日時点の工程を次のように設定する。

- 9月15日～9月27日：モデル・ドメインを選定し、AgentDojoまたは最小環境との接続、正準ツール呼出しのスコアリング、成功判定を動作させる。
- 9月28日～10月11日：80～120実行の予備実験を行い、群分布、スコア算出器、トークン位置、計算時間、保存容量を確認する。
- 10月12日～10月25日：対照対照条件とプロープの妥当性を確認し、条件系列、データ分割、主要層・位置および主解析を凍結する。

4. 10月26日～11月15日：確認的データを収集する。
5. 11月16日～11月30日：主解析、感度分析、図表作成を行い、卒業研究の主要結果を確定する。
6. 12月：再現確認、本文執筆、関連研究の最新版・査読状況の再確認を行う。

活性化パッチングまたは別モデル・別ドメインの実験は、11月10日までに標準達成目標の解析に必要なデータが揃った場合だけ開始する。

11. リスク、継続・中止基準と代替案

- 9月末までにエンドツーエンド実行、自動成功判定または正準呼出しのスコアリングが安定しない場合は、単一の代替ドメインまたはAgentDojo形式を参考にした最小環境へ切り替える。
- 選定モデルが決定論的設定で攻撃なしタスクまたはツール呼出しを安定して実行できない場合は、思考設定を混在させず、別モデルを選ぶか教師強制による行動スコアリングを主解析とする。
- プロンプトが未知の系列で語彙ベースラインを安定して上回らない場合は、「目的表現」という強い主張を下げ、具体的なツール操作・引数表現または時間的な行動帰属へ主題を縮小する。
- `fully_specified`または`param_open`条件で攻撃感受例（Susceptible）が不足する場合は、予備実験で事前評価した攻撃系列または強度を独立要因として追加する。テスト結果を見た後に条件を選び直さない。
- 全Attentionの保存が容量または実行時間を支配する場合は、範囲ごとの集約値だけを残し、残差ストリームと行動スコアを優先する。
- 11月10日までに主解析用データが揃わない場合は、活性化パッチング、Attention介入および別モデル・別ドメイン評価を行わない。
- 活性化パッチングで効果が得られない場合も、観測解析を主成果とし、介入結果は発展的または否定的結果として報告する。

参考文献

- [1] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, and F. Tramèr, "[AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents](#)," NeurIPS 2024 / arXiv:2406.13352, 2024.
- [2] S. Abdelnabi, A. Fay, G. Cherubin, A. Salem, M. Fritz, and A. Paverd, "[Are you still on track!? Catching LLM Task Drift with Activations](#)," arXiv:2406.00799v3, 2024.
- [3] C. Ye, J. Cui, and D. Hadfield-Menell, "[Prompt Injection as Role Confusion](#)," ICML 2026 / arXiv:2603.12277v6, 2026.
- [4] Z. Chen, J. Chen, L. Luo, K. Xu, X. Huang, T. Sun, and X. Jiang, "[IterInject: Indirect Prompt Injection Against LLM Agents via Feedback-Guided Iterative Optimization](#)," arXiv:2605.24659v1, 2026.
- [5] J. Dong, Y. Liu, M. Zhang, et al., "[Your Agentic LLMs Secretly Encode Indirect Prompt-Injection Exposure in Hidden States](#)," arXiv:2608.02657v2, 2026.
- [6] T. Zhang, Y. Xu, J. Wang, et al., "[AgentSentry: Mitigating Indirect Prompt Injection in LLM Agents via Temporal Causal Diagnostics and Context Purification](#)," arXiv:2602.22724v1, 2026.
- [7] X. Ma, T. Li, C. Xiao, Z. Yu, N. Zhang, and Y. Vorobeychik, "[AutoDojo: Adaptive Attacks Expose Superficial Defenses and User-Underspecification Limits in LLM Agents](#)," arXiv:2606.15057v1, 2026.
- [8] J. Hewitt and P. Liang, "[Designing and Interpreting Probes with Control Tasks](#)," EMNLP-IJCNLP 2019.

[9] F. Zhang and N. Nanda, "[Towards Best Practices of Activation Patching in Language Models: Metrics and Methods](#)," ICLR 2024 / arXiv:2309.16042, 2024.