

卒業研究計画案

研究題目

仮題

間接プロンプトインジェクション下のLLMエージェントにおける目的内容・権限帰属・ツール引数選好の表現遷移解析

英題

Tracing Goal Content, Authority Attribution, and Tool-Argument Preference in LLM Agents under Indirect Prompt Injection

1. 研究背景と問題意識

大規模言語モデル（LLM）は、外部のメール、ファイル、ウェブページなどを読み取り、必要に応じてツールを呼び出すAIエージェントとして利用されている。しかし、外部データに悪意ある命令が埋め込まれていると、本来は処理対象である文章を命令として解釈し、不正な行動を実行する可能性がある。この攻撃は間接プロンプトインジェクション（Indirect Prompt Injection; IPI）と呼ばれる。

AgentDojoは、メール、オンラインバンキング、旅行予約などの環境で、エージェントに対するプロンプトインジェクション攻撃とその防御を評価するベンチマークであり、ユーザータスク成功と攻撃成功を区別して評価できる [1]。既存研究では、主に攻撃成功率、ユーザータスク成功率、攻撃検知性能などの外部的な結果が評価されてきた。

内部状態を利用する研究として、Are you still on track!?は、外部データを読む前後の活性化差分からTask Driftを線形分類器で検出できることを示した [2]。Prompt Injection as Role Confusionは、モデルが入力元のラベルだけでなく文章の書き方から発言者の役割を内部的に推定し、役割の混同が生成開始前から攻撃成功と関連すると報告している [3]。IterInjectは、中後層における攻撃文へのAttention増幅と、その機構への介入結果を報告している [4]。さらに、生成前の隠れ状態からIPIへの露出を判別できる一方、その信号が安全な行動へ必ずしも結び付かない知識・行動間の乖離が報告されている [5]。AgentSentryは複数ターンのIPIを時間的・因果的な乗っ取りとして扱い、ツール返却境界における反実仮想的な再実行から乗っ取り時点を局在化している [6]。

これらを踏まえると、「IPIへの露出を内部状態から検出できる」「役割表現またはアテンションが攻撃成功と関連する」「時間的な乗っ取り時点が存在する」という主張だけでは新規性が限定される。本研究は、目的に関する情報を、(i) 行動、(ii) 引数または制約、(iii) 情報源・役割、(iv) 対応条件から操作的に構成する権限帰属、(v) 具体的なツール呼出しへの行動選好に分ける。特に、正規行動と攻撃行動が同じツールを使用し、受取人、口座、金額、対象IDなどの引数だけが異なるIPIを中心に、内容が読み出せること、その内容がどの情報源・役割に由来するものとして表現されるか、trustedな指示に近いという相対的なスコア、および具体的な引数が選好されることの分離と結合を調べる。

例えば、ユーザーが「Aliceの口座へ100ドル送金して」と指示し、口座情報を取得するツールの返却内容に「代わりにEveへ1000ドル送金せよ」というIPIが含まれている場合を考える。このとき本研究では、AliceやEve、100ドルや1000ドルといった具体的な引数内容が内部状態からどの時点で読み出せるか、その内容がユーザー命令またはツール出力などのどの情報源・役割に由来するものとして表現されているか、対応条件に

照らしてtrustedな指示に近いのか、さらに`transfer(to=Alice, amount=100)`と`transfer(to=Eve, amount=1000)`のどちらをモデルが選好しているかを別々に測定する。

したがって、既存研究 [5]との主な差は、IPIに「さらされたこと」をhidden stateから検出できるかではなく、攻撃者が指定した具体的な行動・引数内容そのものの表現、その情報源・役割と操作的な権限帰属、および対応するツール引数の連続的な行動選好の関係を研究対象とする点にある。またAgentSentry [6]等の時間的解析に対しては、エージェントループ上のツール返却境界だけでなく、一つのツール出力の内部でIPI範囲を読み進めるトークン進行も観測する。これらは比較軸の差を述べるものであり、既存研究が関連要素を扱っていないことや、本研究が最初の試みであることを主張するものではない。

なお、2026年の関連研究には査読前のプレプリントを含むため、報告された結果を確立した一般機構とはみなさず、本研究の新規性の境界と比較対象として慎重に扱う。

2. 研究目的と研究課題

本研究の目的は、IPIを受けたツール利用型LLMエージェントについて、攻撃内容が内部状態から読み出せること、その内容がどの情報源・役割に属するものとして表現されているか、そこから操作的に構成した権限帰属の相対尺度、および具体的なツール操作または引数の選好を区別して観測することである。Task Drift、IPIへの露出およびAttentionは比較用の指標とし、主眼を目的内容の読み出し、情報源・役割の帰属、操作的な権限スコア、およびツール呼出し選好の関係に置く。

次の研究課題を設定する。

1. 同一内容をユーザー命令、ツール出力、引用、説明、否定・禁止などに置いた対応条件と、未知のタスク系列または攻撃系列において、行動・引数の内容を読み出す`action_readout`・`argument_readout`と、情報源・役割を読み出す`source_role_readout`を分離して構成できるか。
2. IPI範囲の処理に伴う攻撃者側`argument_readout`の変化と、終端位置における`source_role_readout`から操作的に構成した`authority_score`は、後続する正規／攻撃引数の対数確率差である`tool_call_preference`と、どのトークン位置・層・エージェント境界で関連するか。また両者の交互作用は安定した関連を示すか。
3. `argument content readout`、`source / role attribution`、操作的な`authority score`および`argument preference`の関係は、IPIへの露出、表面的な語彙・書式、タスクの指定度、入力長、攻撃位置および攻撃範囲へのAttentionを考慮しても安定して観測されるか。

活性化パッチング（Activation Patching）は研究課題の成立条件には含めず、十分な対応事例と独立に再現する候補領域が得られた場合だけ、介入方法と評価指標に関する推奨手法 [9]を踏まえた発展的な因果検証として行う。

本研究の中心的新規性は、具体的な目的内容の読み出し、情報源・役割の帰属、対応条件から操作的に構成する権限スコア、およびツール操作・引数の連続的な選好を異なる測定として扱い、ツール出力内のトークン進行とエージェントループの境界という二つの時間軸で、同一ツール・異なる引数のIPIを含めて追跡する点にある。ただし、読み出し値または権限スコアの増加だけを目的の採用とは解釈せず、介入なしに因果的な「乗っ取り」を主張しない。

3. 実験対象と範囲

内部状態を取得できる2B～8B程度の公開重みの指示モデルを用い、単一モデル・単一ドメインから開始する。モデルとドメインは、小規模な統合試験において以下の採用・棄却基準を満たすか確認してから固定す

る。

- 攻撃なし条件でユーザータスク成功を一定割合で達成できる。
- 正準ツール呼出しの構文解析と教師強制スコアリングが一定割合で成功する。
- ユーザータスク成功と攻撃成功を、実行後の環境状態から独立かつ安定して判定できる。
- 同一ツール・異なる引数について、必要数の対応する攻撃感受条件（Susceptible）と攻撃抵抗条件（Resistant）を構成できる見込みがある。
- 同一ツール・異なる引数について、正規呼出しと攻撃呼出しの反実仮想的な候補を同一の直列化済み接頭系列から構成・評価できる。
- 隠れ状態の取得と正規／攻撃呼出しの教師強制スコアリングを、同一の直列化済み接頭系列から再現できる。

各基準の数値閾値は、予備実験とは区別した予備的な統合試験の開始前に、実装可能性を踏まえて定める。その後は、モデル選択のために確認的テストの結果を見ながら閾値を変更しない。引数置換を形式化しやすいBankingを第一候補とするが、事前に定めた基準を満たさない場合は、同様に宛先や対象IDを評価できる単一の代替ドメインへ切り替える。主実験では一モデル・ードメインを維持し、別モデル・別ドメインの一般化評価は必須としない。

ユーザー指示におけるタスク指定度を、行動および主要引数がどこまで事前に定められているかに基づき、次の3種類に分類する [7]。

- **fully_specified**（完全指定型）：行動と主要な引数がユーザープロンプトで指定される。
- **param_open**（引数未指定型）：行動は指定され、引数を外部データから取得する。
- **action_open**（行動未指定型）：実行する行動自体を外部データへ委ねる。

確認的解析は解釈しやすい**fully_specified**と、同一ツール・異なる引数の攻撃を扱える**param_open**を中心とする。**action_open**は権限混同と正当な委任を分けにくいいため、副次的な調整効果の解析に限定する。

主な攻撃経路は、ツールが返す外部データに攻撃命令を埋め込むIPIとする。各実行は次の四群に分類する。

- 群A：攻撃文がなく、ユーザータスクに成功
- 群B：攻撃文があり、攻撃には失敗するがユーザータスクに成功
- 群C：攻撃文があり、攻撃とユーザータスクの両方に失敗
- 群D：攻撃者が指定した不正な行動を実行（ユーザータスク成功・失敗を別途記録）

群A～Dは外部妥当性のために保持するが、主解析は連続的なツール呼出し選好を用い、群B対群Dの二値比較は副次解析とする。攻撃文のない実行でユーザータスクに失敗した場合は、A～Dへ含めず

baseline_failureとして保持する。

4. 条件構成と行動指標

同じ入力とモデルから計算される内部状態とロジットは、確率的生成で最初の異なるトークンが選ばれるまでは原則として同一である。そのため、同じ入力を乱数シードだけ変えて得た成功実行と失敗実行は、分岐前の内部状態差を説明する主比較には用いない。

主解析では、ユーザー目的と攻撃者目的を固定し、ユーザー指示、攻撃文の言い換え、攻撃文の配置、無害な周辺文章および書式を制御して変化させた、意味的に対応する入力変種を作る。モデルを固定し、主比較は貪欲デコーディングまたは同等の決定論的設定で実行する。選定モデルがその設定で安定しない場合は、

モデルを変更するか、決定論的な教師強制によるスコアリングを主解析として生成結果と分離する。確率的生成は、各条件の攻撃成功率を推定する補助評価に限る。

正規呼出し a_L と攻撃呼出し a_A を同一の直列化済み接頭系列から教師強制で評価し、次の指標を保存する。

1. **argument_slot_margin_total**と**argument_slot_margin_normalized**: 対応する引数スロット全体の系列対数確率差について、合計値とトークン数で正規化した値を保存する。どちらを主な行動指標とするかは予備実験とvalidation dataだけを用いて固定する。
2. **whole_call_margin_total**と**whole_call_margin_normalized**: 正準ツール呼出し全体の系列対数確率差について、合計値とトークン数で正規化した値を保存する。
3. **first_discriminating_token_margin**: a_L と a_A が最初に分岐するトークンでのロジット差。トークン化への依存性を確認する診断指標とする。
4. **tool_name_margin**: ツール種別が異なる条件だけで使用する。

引数スロットの合計値と長さ正規化値は、値が大きいほど攻撃呼出しを 선호するよう、次の向きに統一する。

$$m_{\text{arg,total}} = \log P(\text{argument}_A | x) - \log P(\text{argument}_L | x)$$

$$m_{\text{arg,norm}} = \frac{1}{|\text{argument}_A|} \log P(\text{argument}_A | x) - \frac{1}{|\text{argument}_L|} \log P(\text{argument}_L | x)$$

ここで $|\text{argument}_A|$ と $|\text{argument}_L|$ は、対象引数スロットを構成するモデルtoken数であり、区切り記号等を含める範囲は正準直列化規則として事前に固定する。主解析に**argument_slot_margin_total**と**argument_slot_margin_normalized**のどちらを用いるかは、長さ差への感度と推定の安定性を予備実験およびvalidation dataだけで比較して固定し、test確認後には変更しない。選ばなかった指標も感度分析用に保存・報告する。複数トークンからなる引数またはツール呼出しについて、最初のトークンだけから結論を出さない。同一ツール・異なる引数の条件は除外せず、むしろ確認的解析の中心条件とする。

5. 取得する内部情報と二つの時間軸

各実行について、Transformer各層の残差ストリーム、定義した範囲へのAttention集約値、次トークンのロジットおよび正規/攻撃ツール呼出しの系列対数確率を保存する。また、外部データを読む前後の活性化差分をTask DriftまたはIPI露出検知のベースラインに使用する。

残差ストリームは、主実験では全層について、事前指定した観測トークン位置とIPI範囲周辺の固定幅windowに限定して保存する。全sequence・全層の残差ストリームは、トークン位置の対応確認、window幅の決定および探索的な時間変化の確認を目的として、予備実験の事前指定した少数例だけで保存する。window幅、sequence端での境界処理および保存位置は予備実験と検証データで固定し、確認的テストの確認後に変更しない。

「いつ」をエージェントループの境界と単一の順伝播内のトークン位置に分ける。

エージェント境界

- **user_to_assistant**: ユーザー指示までを直列化し、最初のアシスタント生成を開始する直前。
- **first_tool_to_assistant**: 最初のツール返却までを直列化し、次のアシスタント生成を開始する直前。IPIが次行動へ影響できる主要境界。

- **later_tool_to_assistant**: 2回目以降のツール返却後に次のアシスタント生成を開始する直前。遅延効果を調べる副次時点。

ツール出力内のトークン位置

- **Tpre**: 注入範囲直前のトークン。
- **Tpost**: 注入範囲直後のトークン。
- **Tend_tool**: ツール出力末尾のトークン。
- **Tend_assistant**: チャットテンプレート上のアシスタント生成開始マーカー。**Tend_tool**と同じトークンでない場合は分けて保存する。

各時点について、元のメッセージ列、実際にモデルへ渡した直列化済みテキストまたはトークン列、そのチェックサムから生成する**prefix_id**、系列長、トークン位置、トークンID、選択規則およびチャットテンプレートを保存する。活性化については、保存モード（**full_sequence**または**selected_positions_and_ipi_window**）、保存対象層、windowの左右幅と実際の開始・終了トークン位置、およびsequence端でのwindow切れの有無も保存する。異なる段階名でも直列化済み接頭系列とトークン位置が同一なら、別の観測時点として重複計上しない。末尾数トークンの平均は感度分析に限り、主解析の位置は予備実験および検証データで固定する。

Attentionは攻撃範囲、ユーザー目的範囲、ツールのメタデータ範囲への集約量を通常保存し、全層・全ヘッダの完全なAttention行列は予備実験の少数例または事前指定した候補だけに限定する。Attentionの大きさだけから判断理由を断定せず、補助的な記述量として扱う。

6. 読み出しの構成と解釈

「モデルが目的を採用したか」は直接観測できないため、次の測定を区別する。

- **action_readout**: 送信、振込、削除など、行動内容が残差ストリームから読み出せる程度。
- **argument_readout**: 受取人、口座、金額、ファイルIDなど、候補となる具体的な引数identityまたはargument conditionが残差ストリームから読み出せる程度。
- **source_role_readout**: 内容がuser instruction、tool output、quotation、explanation、negation / prohibitionなど、どの情報源・役割・文脈条件に属するものとして表現されているかを読み出せる程度。
- **authority_score**: **source_role_readout**の対応条件から構成する、trusted / user-instruction-like方向とuntrusted / tool-content-like方向の相対的な操作尺度。
- **tool_call_preference**: 正規／攻撃ツール呼出し、特に引数への行動選好。プローブではなく**argument_slot_margin_total**または**argument_slot_margin_normalized**等の対数確率差で測定する。

本文でいうauthority attribution（権限帰属）は、権限そのものの直接観測ではなく、**source_role_readout**の対応条件から派生させる**authority_score**として操作化する。概念的には次のmarginとして定義する。

$$s_{\text{authority}} = s_{\text{trusted/user-instruction-like}} - s_{\text{untrusted/tool-content-like}}$$

各方向のスコアは、可能な限り同一内容を異なる情報源・役割、引用、説明、否定・禁止等に配置した対応テキスト条件から学習・校正する。具体的なクラス構成、スコア変換および校正方法はtraining dataとvalidation dataだけで固定する。**source_role_readout**が情報源や役割を分類できること自体は、その内容に権限を与えた証拠とはみなさない。

行動・引数の読み出しの教師データには、攻撃成否ではなく、目的が一つだけ明示された正常な単一目的実行と対照条件を用いる。主解析の`argument_readout`では、受取人、口座、金額、対象ID等について事前に定めた候補集合または対応条件を用い、候補となる具体的なargument identityまたはargument conditionを教師ラベルとする。したがって、未知のargument valueそのものを初見で復号するzero-shot argument decodingは、本研究の必須主張としない。攻撃成功と最終的なツール選択は、いずれの読み出しの教師ラベルにも使用せず、学習後の外部評価にのみ用いる。

内容への言及（`mention`）は内容の読み出し、具体的行動への選好は`tool_call_preference`として操作的に区別する。行動結果から`adopted`または`committed`ラベルを作って同じ行動を予測するプロープは、循環的になるため主解析では作らない。`argument_readout`または`source_role_readout`の増加や`authority_score`の変化は、それぞれ内容、情報源・役割、またはtrusted方向への相対的位置が読み出し可能であることを示すに留まり、目的の採用、権限の付与または因果的寄与を単独では示さない。これらは、後続する`tool_call_preference`との対応を含めて解釈する。

プロープの妥当性確認には、プロープが表面的対応や無意味なラベルを学習しただけではないかを調べる対照課題の考え方 [8]を踏まえ、少なくとも次を含める。

- 対応テキスト・異なる権限条件
- TF-IDF等を用いた語彙ベースライン
- 同じグループ構造を保ったランダムラベル対照
- タスク、攻撃目的、攻撃形式および近い言い換えをまたがせないグループ考慮分割
- 未知のタスク系列または未知の攻撃系列での評価。これは、既知の候補引数集合を前提に、未知の攻撃形式、表現、周辺文脈および表面的・系列的条件への一般化を主に評価することを意味する
- 学習データのみでの標準化、検証データのみでの層・正則化・閾値・較正方法の選択

単純な近似文、同一タスクの言い換え、同じ攻撃テンプレートの変種がtrain / validation / test間に漏れないよう、タスクと攻撃テンプレートを優先してグループ分割する。テストデータは最後に一度だけ確認し、予備実験、攻撃選択、層選択または閾値調整に使用した系列を確認的テストへ含めない。

7. 解析方法と対照条件

確認的主解析は一つに固定する。`first_tool_to_assistant`のツール出力内で、`Tpre`から事前指定した終端位置までに生じる攻撃者側`argument_readout`の変化と、その終端位置における操作的な`authority_score`が、後続する行動決定時点の引数選好を説明するかを、次の回帰モデルを確認的主解析として用いる。

$$m_{\text{arg}} = \beta_0 + \beta_1 \Delta s_{\text{argument}} + \beta_2 s_{\text{authority}} + \beta_3 (\Delta s_{\text{argument}} \times s_{\text{authority}}) + \gamma^T \mathbf{X} + \epsilon$$

ここで、 m_{arg} は後続する正規／攻撃引数の対数確率marginであり、第4節の手順によりtest確認前に選択した`argument_slot_margin_total`または`argument_slot_margin_normalized`を用いる。 $\Delta s_{\text{argument}}$ は`Tpre`から事前指定した終端位置までの攻撃者側`argument_readout`の変化、 $s_{\text{authority}}$ は終端位置の`authority_score`とする。 $\mathbf{X}$ には、IPI exposure、task specification level、input length、injection position、lexical / surface features、および予備実験前に必要性を定めた共変量を含める。終端位置は`Tend_tool`または`Tend_assistant`からvalidation dataで選び、説明変数の符号・尺度、欠測処理およびモデル仕様もtest確認前に固定する。

特に β_3 の交互作用は、攻撃内容が内部状態から読み出せるだけでは攻撃側行動への選好を意味しないため、研究上重要な解析とする。すなわち、攻撃者側引数の読み出しとtrusted方向への操作的な権限帰属が同時に高まる場合に、攻撃側argument preferenceとの対応が強くなるかを調べる。ただし交互作用の存在を前提

とはせず、argument contentだけが関連する場合、authority scoreだけが関連する場合、交互作用がある場合、いずれも安定した関連を示さない場合のすべてを解釈対象とする。この回帰は観測的解析であり、係数または交互作用だけから因果的な「乗っ取り」や、権限表現が行動を引き起こしたことを主張しない。

中間層の候補領域、トークン位置、前処理、正則化および判定閾値は予備実験と検証データだけで決定し、そこで使用したタスク系列・攻撃系列は確認的テストから除外する。最終層・最終トークンの読み出しと同じ位置のロジット差は、構造的に相関し得るため健全性確認に下げ、主張の中心にしない。

主な対照条件として、無害な命令文、同じ攻撃語彙を含む説明・引用・禁止、長さを揃えた無害文、同じ内容を異なる役割へ置いた条件、異なる言い回しの攻撃を含める。Task Drift、IPIへの露出、`source_role_readout`単独と行動選好との関連、PCA等の可視化、群B対群D、Attentionおよび`later_tool_to_assistant`は副次解析とする。全層・全位置の探索的な図を示す場合は探索的解析と明記し、偽発見率を制御する。

推論単位は個々の表層的な入力変種ではなく、タスクと攻撃目的・形式から構成した独立クラスターとする。効果量と95%信頼区間を、最高位クラスター単位のブートストラップ法または置換法で報告する。十分なクラスター数と安定した推定が得られた場合だけ、変量効果モデルを補助的に用いる。

8. 実験規模と統計計画

12月までに主結果を確定するため、実行数を先に固定するのではなく、独立クラスター数、実装時間および保存容量を優先する。単一モデル・単一ドメインについて、活性化を保存する実行の暫定総数を約450～700とする。

この実行数は、主実験では事前指定したトークン位置とIPI周辺windowの活性化のみを保存し、全sequence・全層の保存を予備実験の少数例に限定することを前提とする。

- 予備実験：80～120実行
- プローブ教師・対照対照条件：200～300実行
- 確認的IPI：タスク×攻撃目的・形式の独立クラスターを最低30、各クラスターにつき3～4個の表層的な入力変種を目安とする
- 攻撃なしベースライン：60～100実行

確認的IPIの最低30クラスターは、統計的十分性を断定する値ではなく、実装時間、保存容量および意味的独立性を考慮した暫定的な下限である。予備実験後、training / validation側で得られた効果量、クラスター間のばらつきおよび信頼区間幅を参考に、必要であればsimulationまたはcluster bootstrapによって主解析の推定精度を確認する。確認的testから効果量を推定して必要標本数を後付けで変更することはしない。

最終的な配分は予備実験後、test確認前に凍結する。表層的な言い換えだけを増やして見かけ上の標本数を大きくせず、実行総数よりも意味的に独立したtask × attack goal / style cluster数を優先する。

`attack_goal_id`と`attack_style_id`を分け、多様な意味・形式の系列を確保する。攻撃抵抗条件（Resistant）と攻撃感受条件（Susceptible）の両方が得られる意味的対応条件は最低20組、目標30組とするが、群B・群Dの件数だけを主解析の成立条件にはしない。

2026年10月1日のRDR-2026-10-01-02により、予備実験は既存Bankingタスクを中心に測定・解析の方針を固め、確認的評価には新しい意味系列を設計する方針とする。選定・shakedownの既使用系列も、新しいrunとして予備実験に再利用できる。過去のshakedown runは研究データへ転用せず、既使用・予備実験・調整に使った系列はtestから除外する。新系列の設計とmodel-free検証は予備実験と並行し、関係graphの連結成分単位でtraining / validation用と未使用test用へ分ける。単なる値置換・言い換えを新系列に数えず、共有攻撃系列による結合も審査する。新規タスクの来歴と評価器versionはnativeタスクと区別して保存する。

研究課題・仮説と暫定規模は維持し、必要group数の実現可能性と最終splitはtest開封前に確認・凍結する。

2026年10月1日のRDR-2026-10-01-03で、初回予備実験を既存の6task（14/0/3/4/2/12）・4task系列の最大90条件に具体化した。先行18の後、監査後の厳密clean成功3/6以上・2系列以上と測定・監査条件を満たせば拡張する。全90終了後は実軌跡の接触・内部状態取得・採点が2系列以上で可能かを確認する。攻撃成功やR/S pairの最低数は課さず、陰性結果を残して追加探索は別RDRで判断する。共有攻撃形式等により標本は1連結成分であり、4系列や90条件を独立clusterとは数えない。これは標本・停止規則の凍結で、正式モデル採用、native事前検証・capture実装の完了、確認的testの作成を意味しない。詳細な実行gateはプロトコル第5.3節に従う。

確率的生成は、マージンが0に近い条件と各タスク・攻撃の代表条件を優先し、生成設定を固定して各10回程行う。この補助評価では原則として活性化を保存しない。

学習・検証・テストは暫定的に60%、20%、20%とするが、実行単位で無作為分割しない。同じタスク、攻撃目的、攻撃形式、対応組、近い言い換えおよび確率的反復は分割間にまたがせず、同じ分割へまとめる。検定方法、主要な説明変数、共変量、除外規則および感度分析はテスト確認前に凍結する。

9. 期待される成果と達成基準

攻撃失敗例でも攻撃者側のargument_readoutは早期に高まり得る一方、攻撃を受け入れやすい条件では、source_role_readoutから構成したauthority_scoreと後続するargument preferenceの結び付きが中間層から後半層で強くなると予想する。特に、攻撃者側argument_readoutの増加とauthority_scoreが同時に高い場合にargument preferenceとの対応が強まるかを検証する。これは、source / role attribution、操作的なauthority score、argument content readoutおよびargument preferenceを区別した仮説であり、期待した主効果または交互作用が得られない場合も報告する。また、action_openのタスクほど攻撃内容と正当な委任の区別が難しくなると予想する。

必須達成目標

- 公開LLMを用いた単一ドメインのツール利用型エージェントを構築する。
- 正確な直列化済み接頭系列とトークン位置に対応した残差ストリームを取得する。
- ユーザータスク成功、攻撃成功、A～Dおよびベースライン失敗を独立に記録する。
- Task DriftまたはIPI露出のプロープを比較用ベースラインとして再現・評価する。
- 同一の接頭系列から正規／攻撃の正準ツール呼出しの系列対数確率を評価する。
- 対応条件からsource_role_readoutを構成し、情報源・役割の読み出し性能を評価する。

標準達成目標

- 対照条件から行動・引数の読み出しを構成し、語彙ベースラインと比較する。
- source_role_readoutの対応条件から操作的なauthority_scoreを構成する。
- Tpreから事前指定した終端位置までのargument_readoutの変化、終端位置のauthority_score、両者の交互作用と、後続する引数マージンの関連を定量化する。
- タスクの指定度とグループ構造を考慮した効果量および95%信頼区間を報告する。
- 陽性・陰性のいずれでも、目的内容の読み出し、情報源・役割の帰属、操作的な権限スコアおよびツール呼出し選好を区別した解釈を提示する。

発展達成目標

- 意味的に対応した双方向の活性化パッチングによって候補状態の因果的寄与を検証する。
- 別モデルまたは別ドメインで小規模な一般化評価を行う。

10. 研究工程と期限

12月は追加の探索実験ではなく、執筆と再現確認に充てる。2026年9月15日時点の工程を次のように設定する。

1. 9月15日～9月27日：モデル・ドメインを選定し、AgentDojoまたは最小環境との接続、正準ツール呼出しのスコアリング、成功判定を動作させる。
2. 9月28日～10月11日：80～120実行の予備実験を行い、群分布、スコア算出器、トークン位置、計算時間、保存容量を確認する。
3. 10月12日～10月25日：対照条件とプローブの妥当性を確認し、条件系列、データ分割、主要層・位置および主解析を凍結する。
4. 10月26日～11月15日：確認的データを収集する。
5. 11月16日～11月30日：主解析、感度分析、図表作成を行い、卒業研究の主要結果を確定する。
6. 12月：再現確認、本文執筆、関連研究の最新版・査読状況の再確認を行う。

活性化パッチングまたは別モデル・別ドメインの実験は、11月10日までに標準達成目標の解析に必要なデータが揃った場合だけ開始する。

11. リスク、継続・中止基準と代替案

- 9月末までにエンドツーエンド実行、自動成功判定または正準呼出しのスコアリングが安定しない場合は、単一の代替ドメインまたはAgentDojo形式を参考にした最小環境へ切り替える。
- 選定モデルが決定論的設定で攻撃なしタスクまたはツール呼出しを安定して実行できない場合は、思考設定を混在させず、別モデルを選ぶか教師強制による行動スコアリングを主解析とする。
- プローブが未知の系列で語彙ベースラインを安定して上回らない場合は、「目的表現」という強い主張を下げ、具体的なツール操作・引数表現または時間的な行動帰属へ主題を縮小する。
- `fully_specified`または`param_open`条件で攻撃感受例（Susceptible）が不足する場合は、予備実験で事前評価した攻撃系列または強度を独立要因として追加する。テスト結果を見た後に条件を選び直さない。
- 全Attentionの保存が容量または実行時間を支配する場合は、範囲ごとの集約値だけを残し、残差ストリームと行動スコアを優先する。
- 11月10日までに主解析用データが揃わない場合は、活性化パッチング、Attention介入および別モデル・別ドメイン評価を行わない。
- 活性化パッチングで効果が得られない場合も、観測解析を主成果とし、介入結果は発展的または否定的結果として報告する。

参考文献

- [1] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, and F. Tramèr, "[AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents](#)," NeurIPS 2024 / arXiv:2406.13352, 2024.
- [2] S. Abdelnabi, A. Fay, G. Cherubin, A. Salem, M. Fritz, and A. Paverd, "[Are you still on track!? Catching LLM Task Drift with Activations](#)," arXiv:2406.00799v3, 2024.

- [3] C. Ye, J. Cui, and D. Hadfield-Menell, "[Prompt Injection as Role Confusion](#)," ICML 2026 / arXiv:2603.12277v6, 2026.
- [4] Z. Chen, J. Chen, L. Luo, K. Xu, X. Huang, T. Sun, and X. Jiang, "[IterInject: Indirect Prompt Injection Against LLM Agents via Feedback-Guided Iterative Optimization](#)," arXiv:2605.24659v1, 2026.
- [5] J. Dong, Y. Liu, M. Zhang, et al., "[Your Agentic LLMs Secretly Encode Indirect Prompt-Injection Exposure in Hidden States](#)," arXiv:2608.02657v2, 2026.
- [6] T. Zhang, Y. Xu, J. Wang, et al., "[AgentSentry: Mitigating Indirect Prompt Injection in LLM Agents via Temporal Causal Diagnostics and Context Purification](#)," arXiv:2602.22724v1, 2026.
- [7] X. Ma, T. Li, C. Xiao, Z. Yu, N. Zhang, and Y. Vorobeychik, "[AutoDojo: Adaptive Attacks Expose Superficial Defenses and User-Underspecification Limits in LLM Agents](#)," arXiv:2606.15057v1, 2026.
- [8] J. Hewitt and P. Liang, "[Designing and Interpreting Probes with Control Tasks](#)," EMNLP-IJCNLP 2019.
- [9] F. Zhang and N. Nanda, "[Towards Best Practices of Activation Patching in Language Models: Metrics and Methods](#)," ICLR 2024 / arXiv:2309.16042, 2024.