# 送金先プローブはなぜ働かなかったのか：検証できたこと・まだ検証していないこと

**報告日**：2026-10-30　**対象**：2026-10-27報告「AIエージェントの『送金先の判断』を内部状態から読み取れるか」の事後検証　**状態**：学習用データ（480条件）だけを使った探索的な診断。検証用データは今回新たに見ていない。

> **要点1**：モデル自身は、送金先と参照口座をほぼ正しく区別している（480条件中469件、97.7%）。情報はモデルの中にある。
> **要点2**：評価の計算と口座の割り当てに誤りは見つからなかった。
> **要点3**：応答直前の内部状態からは、どの層でも「送金先か」どころか「その口座が文面にあるか」さえ読み取れない。問題は学習量ではなく**読み取る位置か方法**にある可能性が高い。

## 1. 前回の結果と、今回の3つの問い

前回は、応答を始める直前の位置（1トークン分）の内部状態から、各口座が「送金先か」を判定するプローブ（単純な線形判定器）を学習した。学習量を480条件まで増やしても検証用での成績（AUROC）は最大0.613で、到達基準0.80に届かなかった。原因を切り分けるため、次の3つを調べた。

- **問いA**：そもそもモデル自身は、送金先と参照口座を区別できているのか。
- **問いB**：成績の計算に誤りはないか。0.5を大きく下回る値が出ることがあるのはなぜか。
- **問いC**：口座の割り当てや、学習データのラベルの作り方に問題はないか。

問いCの確認では、学習用データの中で「話題（シリーズ）を1つ除いて学習し、除いた話題で評価する」ことを40話題すべてで繰り返した（交差検証）。未知の話題への当てはまりを、検証用データに触れずに調べられる。

## 2. 検証できたこと

### 問いA　モデル自身は区別できている　（確認済み）

モデルが送金の命令を書き始める時点で、各口座番号を「次に書く」確からしさ（対数確率）を計算した。モデルが実際に使う書き出し（`"recipient": "` まで）をそろえ、口座番号の部分だけを比べている。文面にある口座のうち送金先の確からしさが最も高かったのは**469/480件**（97.7%）で、プローブと同じ指標に直すと**AUROC 0.87〜0.91**（学習データの5区分）だった。モデルは送金先を正しく扱えており、取り出せないのはプローブ側の問題と言える。

### 問いB　計算に誤りはない　（確認済み）・低い値の原因　（推定のみ）

成績の計算を別の方法で一から作り直し、学習曲線の5段階すべてで元の計算と完全に一致した。話題ごとの成績は0.06〜0.89と大きくばらつくが、1話題あたりの評価点が12個しかないため、偶然でも±0.17程度は動く（計算上の見積もり）。0.5を大きく下回る値は、この偶然の揺れで説明できる範囲と考えられる。ただし、実際にでたらめな学習を繰り返して確かめてはいない。

### 問いC　口座の割り当ては問題なし　（確認済み）・ラベルの偏りは原因ではない　（確認済み）

4つの口座は学習用・検証用で共通で、「送金先×参照口座」の組み合わせも均等だった。一方、ある口座について学習ラベルを数えると、大半は「その口座が文面に出てこない」例だった（図2）。そのためプローブは「口座が文面にあるか」だけを覚え、役割の区別を学んでいないのではないかと考えた。

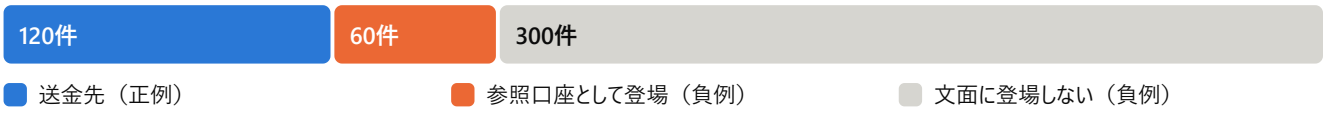



*図2　候補口座1つ分の学習ラベルの内訳（480条件、4口座とも同じ）。「文面にあるか」だけで判定しても学習データ上ではほぼ当たってしまう構成になっている。*

しかし交差検証で層ごとに調べると、プローブは役割（0.50〜0.57）だけでなく、口座が文面にあるか（0.54〜0.56）すら未知の話題では読み取れなかった（図1）。文面に口座がある例だけで学習し直しても、役割の成績は0.51〜0.53で改善しなかった。したがって「**有無だけを覚えた」という仮説は誤り**で、ラベルの偏りは主因ではない。

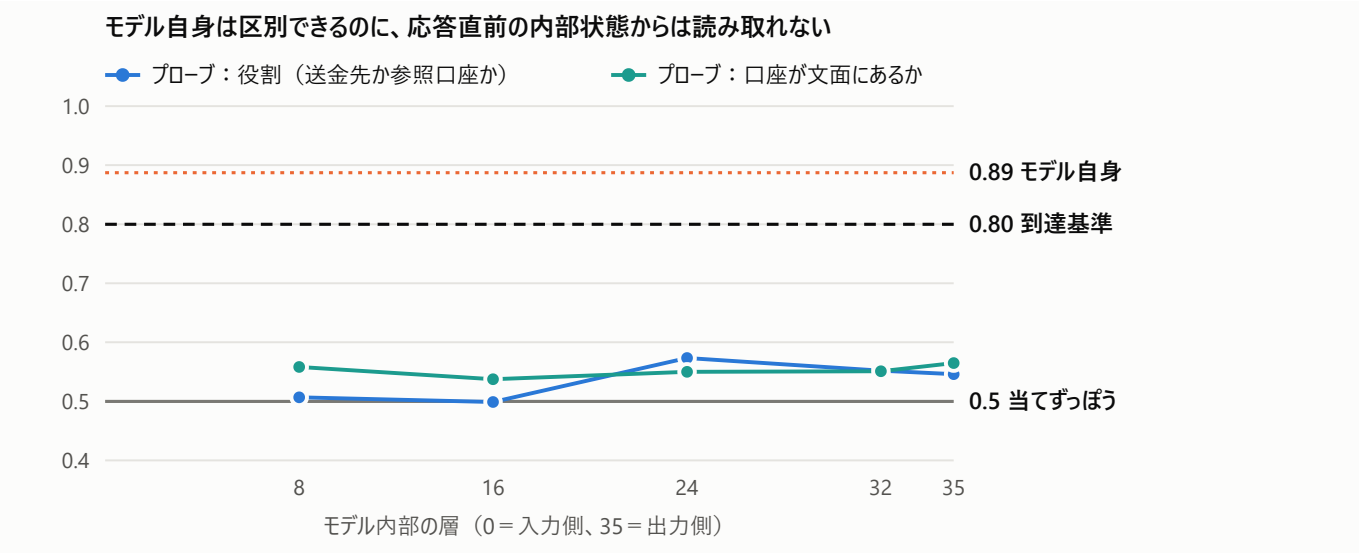



*図1　学習用データの交差検証での、プローブの読み取り成績（AUROC）。橙の点線は、同じ条件・同じ指標でのモデル自身の対数確率による値。交差検証の値は探索的な実行（乱数ラベル対照なし）の出力。同じ手順の本実行が進行中。*

**現時点の解釈：**応答直前の1点には、少なくとも単純な線形判定器で取り出せる形では、口座の情報が入っていない。モデルは口座番号を書くその時点で、文中の口座番号を参照し直しているのかもしれない。前回、口座番号そのものの位置では非常に高い成績が出ていたことも合う。ただし、これは結果と矛盾しない仮説にすぎず、検証していない。

## 3. まだ検証していないこと

| 項目 | なぜ重要か | 今後 |
|---|---|---|
| 口座の情報が**どの位置**にあるか | 応答直前にないなら、どこで読めるかが研究の中心になる。今回の結果は「応答直前にはない」までしか言えない。 | 位置を変えた再取得が必要（次の一手） |
| 検証用データでのモデル自身の確からしさ | 今回は学習用だけで計算した。検証用のデータを見る回数を増やさないため、意図的に計算していない。 | 必要になった時点で判断 |
| 低い値が偶然の揺れで説明できるか | 計算上の見積もりだけで、でたらめな学習を繰り返した実測はしていない。 | 追加の計算で確認できる |
| 旧96条件の交差検証で出た0.219 | 672条件での傾向から類推しただけで、旧結果そのものは解析し直していない。 | 必要なら再解析 |
| 前処理（標準化）の独立な検証 | 記録と実装を読んで確認しただけ。 | 優先度は低い |
| 設定の幅 | 正則化の強さは1通り、モデルは軽量化（8bit）版のみ、書き出しの形式も1通り（実際の112回の実行はすべてこの形式）。 | 位置の検証と合わせて判断 |

## 4. 次の一手（未決）

学習データを増やしても改善は見込みにくい。**読み取る位置を変えて内部状態を取り直す**のが次の候補である。（1）文中の各口座番号の上で、その口座の役割を読む位置、（2）モデルが口座番号を書き始める直前の位置、の2つを考えている。いずれも新しい取得と、事前に手順を固定する記録（RDR）が必要で、着手は研究実施者の判断による。

**参照：**診断コード `argument_recipient_672_train_readout.py`・`argument_recipient_672_recipient_logprob.py`（commit 9698029）、設定 `configs/analysis/phase2_argument_recipient_672_train_readout_diagnostic_v1.json`。前回報告：`output/pdf/2026-10-27_recipient_probe_learning_curve_summary.pdf`