AIは「誰に送金するか」を、いつ決めているのか

これから行う3つの手順の説明（2026年11月6日時点。3つとも、これから実施するものです）

> **この資料の要点：**AIは送金先をほぼ正しく扱えるのに、「AIが答え始める直前の内部の様子」を調べても、送金先を読み取れませんでした。そこで、**送金先がいつ決まっているのかを3つの手順で確かめます。**これは、AIをだまして送金先をすり替える攻撃の仕組みを理解するための土台です。

背景：何を調べている研究か

最近のAIは、文章を返すだけでなく、書類を読み、送金などの操作も代行できるようになっています。ここで問題になるのが、**読ませる書類に悪意のある指示を紛れ込ませる攻撃**です。たとえば請求書の中に「振込先はこちらの口座に変更」と書いておき、AIに信じ込ませます。

特にやっかいなのは、**送金という操作は正しいまま、送金先だけがすり替わる**場合です。外から見ると普通の送金に見えます。この研究では、そのときAIの内部で何が起きているのかを調べます。

これまでに分かったこと

まず攻撃のない場面で、AIの内部の様子から「送金先の口座」を読み取れるかを試しました。人間でいえば、頭の中をのぞいて考えを読み取るような試みです。

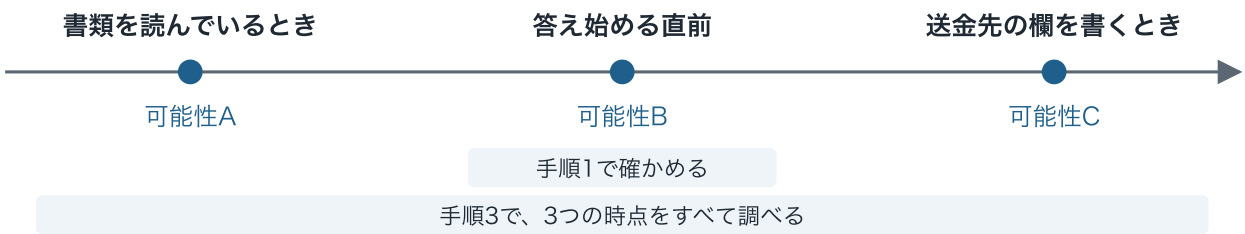
- **AIは送金先を区別できていました。**こちらで送金の書き出しまで与えて続きを予測させると、480件中469件で正しい送金先を最も有力と見なしました。
- **それでも、答え始める直前の内部の様子からは読み取れませんでした。**学習用の例を480件まで増やしても、目標の精度には届きませんでした。

AIの中に情報はあるはずなのに、調べた時点では見つからなかったことになります。理由はまだ分かっていません。考えられる可能性は、経理担当者にたとえると次の3つです。

可能性A：読んだときに決まる
書類を読みながら、口座番号に「これが送金先」と付箋を貼っている。

可能性B：答え始める直前に決まる
番号そのものは覚えていないが、「上に書かれた方を使う」とだけ決めている。

可能性C：書くときに決まる
送金先の欄を埋める瞬間に書類を見返して、初めて決めている。



手順1　同じ記録を、別の問いで調べ直す

やること

答え始める直前の記録を、新しい問いで分析します。前回は「この口座は送金先か」と口座ごとに問いました。今回は、どの口座かを問わず**「送金先は先に書かれた方か、後に書かれた方か」**を問います。新たにAIを動かす必要はありません。

なぜやるか

- **前回の問い方では見逃す可能性があるからです。**AIが「先に書かれた方」という形で覚えていても、同じ口座が先に出る例と後に出る例が混ざるので、口座ごとに調べると手がかりが打ち消されてしまいます。
- **調べる道具が壊れていないか確認するためです。**今は「情報がない」のか「道具が何も読めていない」のかを区別できません。そこで、確実に読めるはずの情報も一緒に読み、温度計を試すように道具を点検します。

何が分かるか

- 読み取れれば、**可能性Bが有力な候補**になります。
- 読み取れなければ、少なくともこの単純な形では見つからないので、可能性AとCを中心に調べます。
- 確実な情報すら読めなければ、道具の問題なので、結果の解釈はせずに原因を調べます。

限界

読み取れない結果になる可能性が高いと見ています。また、読み取れても、文の順番を覚えているだけかもしれず、「決めている」証拠にはなりません。

手順2　AIの失敗の中身を分類する

やること

AIに実際に作業させた記録を読み、失敗の種類を分けます。主な対象は次の3つです。

- 別の口座へ送金してしまった14件（112件中）。候補を取り違えたのか、番号を書き写し損ねたのか。
- 送金先を依頼文で直接伝えた場合の成功が64件中21件と低いこと（書類で伝えた場合は48件中46件）。原因は送金先か、書類の読み忘れや金額などの別の誤りか。
- 以前の予備実験で攻撃者の指示どおりに動いた31件。送金先だけのすり替えは何件で、別の操作をさせられたものは何件か。

なぜやるか

- **もともとの失敗と攻撃の影響を区別するためです。**攻撃がなくても失敗が多い場面で攻撃を試すと、失敗の原因が攻撃なのか判断できません。
- **研究したい攻撃が十分に起きるか確かめるためです。**この研究の対象は送金先だけのすり替えです。それが少なければ、実験の設計を見直す必要があります。

何が分かるか

AIが「どこまで正しく扱えているのか」の実態と、**今後の攻撃実験で何と何を比べればよいか**が分かります。内部の仕組みではなく、行動について調べる手順です。

手順3　いくつもの時点で、内部の様子を記録し直す

やること	1ページ目の図の時点ごとに、AIの内部の様子を新しく記録します。特に、書類の口座番号を読んでいるとき、送金先の欄を書き始めるとき、そして**番号が口座ごとに違ってくる桁を書くとき**を分けて調べます。どの口座も同じ「GB」で始まるので、書き始めの瞬間だけでは、どの口座を選んだのかが分からないためです。比較には、**同じ2つの口座のまま、役割の文だけを入れ替えた組**を使います。
なぜやるか	これまで調べたのは「答え始める直前」の1時点だけです。そこに見つからないなら、別の時点を測らないと、どこにあるのかは答えられません。
何が分かるか	送金先の情報が**どの時点で読み取れるようになるか**が分かり、可能性A、B、Cのどれに近いかを判断する材料になります。どれにも当てはまらなければ、その結果も報告します。
限界	読み取れることと、それで行動が決まることは別です。また、書く直前の時点は、次に書く文字の予測と結びつくので、読み取れて当然という面があります。その分を差し引いて評価します。

3つの手順のあとに残ること

> **この3つでは、まだ攻撃の仕組みまでは分かりません。**手順1と3は主に攻撃のない場面を調べるものなので、分かるのは「通常の作業で送金先がいつ決まるか」です。攻撃を受けたときにそれがどう変わるかは、手順2の結果を踏まえて、この後で実験を組み立てます。限られた期間の中で、ここが最大の課題です。

また、内部の様子を読み取るだけでは、それが行動の原因だとは言えません。原因かどうかを確かめるには、内部の状態を実際に入れ替えて行動が変わるかを試します。この実験は、2026年11月20日までに始められる場合に限り、試行的に行います。卒業論文の主な結論や題目を見直すかは、これらの結果を見てから判断します。

数値は開発中の試行結果で、最終的な評価用データによる確認ではありません。480件中469件は学習用データでの試行的な確認、112件の結果は自動判定とAIによる確認で、人による全件確認ではありません。